

KGGen: 使用语言模型从纯文本中提取知识图谱

Belinda Mo^{1, 2}, Joshua Kazdan¹,
琼·卡贝萨斯³, 骄傲的 Mpala¹, Lisa Yu²,
克里斯·坎迪⁴, 查里劳斯·卡纳特苏利斯¹, Sanmi Koyejo¹
¹斯坦福大学²多伦多大学³独立的⁴Al大灯

抽象的

近年来,构建知识图谱基础模型的研究热潮凸显了一个根本性的挑战:知识图谱数据稀缺。目前最知名的知识图谱主要由人工标注、模式匹配或早期自然语言处理技术提取而成。人工生成的知识图谱数量有限,而自动提取的知识图谱质量也参差不齐。我们提出了KGGen,一种新型的文本到知识图谱生成器。它利用语言模型,通过一种新颖的实体解析方法从纯文本中提取高质量的知识图谱。该方法能够对相关实体进行聚类,从而显著降低现有提取器普遍存在的稀疏性问题。与其他知识图谱生成器不同,KGGen通过对相关实体进行聚类 and 去重来降低提取的知识图谱的稀疏性。除了KGGen之外,我们还发布了节点和边信息度量 (MINE),这是首个用于测试提取器从纯文本生成有用知识图谱能力的基准测试工具。我们将新工具与微软GraphRAG等领先的现有生成器进行了对比测试。我们在生成的图上实现了相当的检索准确率和更好的信息保留率。此外,我们的图展现出更简洁、更具通用性的实体和关系。我们的代码已在 <https://github.com/stair-lab/kg-gen/> 开源。

1 引言

知识图谱 (KG)应用和基于图的检索增强生成 (RAG)系统正日益受到可用知识图谱稀缺性和不完整性的制约。知识图谱由一组主语-谓语-宾语三元组构成,已成为信息检索的基本数据结构[Schneider, 1973]。大多数现实世界的知识图谱,包括Wikidata[contributors, 2024]、DBpedia[Lehmann et al., 2015]和YAGO[Suchanek et al., 2007],都远非完整,实体之间存在许多缺失的关系[Shenoy et al., 2021]。缺乏特定领域且经过验证的图数据对下游任务 (例如知识图谱嵌入、图RAG和合成图训练数据)构成了严峻挑战。

为了解决知识图谱稀缺的问题,人们提出了多种合成的纯文本到知识图谱提取器,其中最著名的包括 OpenIE [Angeli et al., 2015] 和微软的 GraphRAG [Larson and Truitt, 2024]。OpenIE 和 GraphRAG 都直接从文本中提取实体和关系,但它们缺乏有效的实体解析和关系规范化机制。这导致生成的图谱中关系类型几乎与边的数量一样多,从而产生稀疏且不连通的知识表示,限制了它们在下游任务中的应用。为了解决这个问题,我们提出了 KGGen,一个利用语言模型 (LM) 和实体及边解析算法从文本中提取高质量、密集知识图谱的文本到知识图谱生成器。首先,KGGen 使用基于语言模型的提取器读取非结构化文本并预测主谓宾三元组以捕获实体和关系;提取三元组后,它应用一种新颖的迭代聚类算法来优化知识图谱。

*同等贡献。

2502.09956v2

原始图。受众包实体解析策略的启发 [Wang et al., 2012], KGen 识别指代相同底层实体的节点, 合并并具有相同含义的边。

目前, 从纯文本到知识图谱的提取这一新兴领域缺乏衡量文本生成知识图谱质量的基准。为了弥补这一空白, 我们提出了两个新的基准: 第一个基准衡量从短文本中获取信息的能力; 第二个基准基于 WikiQA, 衡量从包含数百万个词元的网络知识库生成的知识图谱的知识检索能力。

在这些基准测试中, KGen 的性能与 GraphRAG 相当。然而, 随着纯文本数据库长度的增加, KGen 在信息压缩和图稀疏性方面表现出更好的扩展性。

总结我们的贡献:

1. 我们介绍 KGen, 这是一个使用语言模型提取高质量知识图谱的开源软件包。
从纯文本转换。我们的软件包以 Python 库的形式提供。
2. 我们开发基准来推动纯文本到知识图谱提取的改进, 并衡量 KGen 在这些基准上的性能。
3. 我们证明, KGen 在文本源规模方面具有更优的可扩展性。
与以往的方法相比。

2 相关工作

早在2001年, 当大量纯文本开始涌入新兴的互联网时, 人们对利用自动化方法生成结构化文本以存储本体的兴趣就已萌芽 [Maedche and Staab, 2001]。过去15年来, 基于规则和语言模型 (LM) 的方法在从非结构化文本中提取知识图谱方面取得了显著进展。早期研究 [Suchanek et al., 2007] 使用硬编码规则开发了 YAGO, 这是一个从维基百科中提取的包含超过500万条事实的知识图谱。如今, 基于规则的提取方法对于在多模态领域构建知识图谱的研究人员仍然具有吸引力 [Norabid and Fauzi, 2022, Oramas et al., 2015]。随着现代自然语言处理技术的发展, 硬编码规则逐渐被基于神经网络的更先进方法所取代。例如, OpenIE [Angeli et al., 2015] 提供了一个两层提取系统: 首先, 通过分类器识别自包含子句; 然后, [Angeli et al., 2015] 运行自然逻辑推理, 从识别出的子句中提取最具代表性的实体和关系。Stanford KBP [Angeli et al., 2013] 提出了另一种使用深度网络进行实体提取的早期开创性方法。

早在2015年, 就有学者提出知识图谱 (KG) 的提取与更优秀的语言模型开发相辅相成 [Domeniconi et al., 2015]。近年来, 越来越多的证据表明, 基于 Transformer 的架构能够识别实体间复杂的关联关系, 由此催生了一系列基于 Transformer 的知识图谱提取技术, 涵盖了从全自动 [Qiao et al., 2022, Arsenyan et al., 2023, Zhang and Soh, 2024] 到人工辅助 [Kommineni et al., 2024] 等多种方法。我们对知识图谱提取文献的贡献在于构建适用于 TransE 和 TransR 等嵌入算法的知识图谱 [Bordes et al., 2013, Lin et al., 2015]。我们观察到, 从纯文本中提取知识图谱时, 节点和关系往往非常具体, 以至于它们是唯一的。这导致嵌入估计不够精确。我们开发了一种从纯文本中自动提取知识图谱的方法, 该方法通过对相似的节点和边进行聚类来防止知识图谱欠定义。这使得知识图谱具有更好的连通性以及更多功能性节点和边。

评估知识图谱的质量对于确保其在下游应用中的实用性和可靠性至关重要。早期的评估方法主要集中于直接评估完整性和连通性等方面, 或使用基于规则的统计方法, 而最近的方法则强调在下游应用中的可用性以及语义一致性的融入 [Xue and Zou, 2023]。

在2000年代后期, 研究重点转向评估知识图谱的正确性和一致性。评估方法依赖于专家标注, 即从生成的知识图谱中随机选择事实, 然后计算这些事实的准确率。[Suchanek et al., 2007] 这种方法被证明既费时又容易出错。因此, 出现了诸如 KGEval [Ojha and Talukdar, 2017] 和双状态权重聚类采样 (TWCS) [Gao et al., 2018] 等准确率近似方法, 这些方法采用具有统计保证的抽样方法, 并且标注工作量更少。随着知识图谱规模的扩大, 评估方法也变得更加复杂。

随着网络数据自动提取技术的兴起,知识图谱变得更加多样化,这给标注者带来了更大的压力,促使人们采用蒙特卡洛搜索等方法对三元组进行交互式标注[Qi et al., 2022]。此外,由于仅凭准确率无法完全反映知识图谱的复杂性,因此需要使用完整性等更多评估指标来表征知识图谱的质量[Issa et al., 2021]。

近年来,知识图谱 (KG) 的评估越来越关注其在下游人工智能应用中的作用,例如增强语言模型[Schneider et al., 2022]和推荐系统[He et al., 2020]。因此,语义一致性和可用性已成为评估提取的知识图谱质量的关键标准。

知识图谱评估的两种主要方法是LP-Measure和三元组可信度量 (KGTm) 模型。LP-Measure通过链接预测任务评估知识图谱的质量,无需人工干预或黄金标准[Zhu et al., 2023]。该方法通过移除知识图谱的一部分,并测试移除的三元组是否可以通过链接预测工具恢复,从而基于知识图谱的一致性和冗余性对其进行评估。实证研究表明,LP-Measure能够有效区分“好”知识图谱和“坏”知识图谱。另一方面,KGTm模型评估知识图谱中三元组的一致性[Jia et al., 2019]。

基于这些评估方法,出现了诸如基于下游任务的知识图谱评估 (KGrEaT) 和差异化测试 (DiffQ) 等框架。KGrEaT通过评估知识图谱在分类、聚类和推荐等下游任务上的性能,而非仅仅关注其正确性或完整性,从而对知识图谱进行全面评估[Heist et al., 2023]。

相比之下,DiffQ 使用嵌入模型来评估知识图谱的质量并分配 DiffQ 分数,从而提高了知识图谱的质量评估 Tan 等人 [2024]。

3. 现有方法

在介绍 KGen 之前,我们先解释两种流行的从纯文本中提取知识图谱的现有方法,这将作为本文其余部分进行比较的基础。

3.1 OpenIE

开放信息抽取 (OpenIE) 由斯坦福CoreNLP团队基于Angeli等人[2015]的研究成果实现。它首先使用斯坦福CoreNLP流程为每个句子生成“依存句法分析”。然后,训练好的分类器遍历依存句法分析中的每个边,决定是否创建、继续或停止处理某个从句。这些决策将复杂的句子拆分成更短、更独立的从句。系统从这些从句中生成 (主语、关系、宾语) 元组,每个元组都附带一个置信度分数。由于OpenIE不要求输入文本具有特定的结构,因此它可以处理任何格式的文本。

3.2 GraphRAG

GraphRAG 由微软于 2024 年开发,它将基于图的知识检索与语言模型 (LM) 相结合 [Larson 和 Truitt, 2024]。首先,GraphRAG 提供从纯文本生成知识图谱的功能,这些知识图谱作为其检索数据库。在此过程中,GraphRAG 通过提示语言模型提取节点实体及其之间的关系来创建图。在整个提取过程中,少样本提示为语言模型提供理想提取的示例。GraphRAG 将连接良好的节点聚合到社群中,并为每个社群生成摘要。最终的图由节点及其关系、社群及其摘要组成。

4 KGen:从纯文本构建知识图谱

与以往大多数基于 LLM 的知识图谱提取方法不同,我们采用多阶段方法: (1) 使用 LLM 从每个源文本中提取实体和关系; (2) 跨源聚合图; (3) 使用 LLM 和传统信息检索方法的混合方法迭代地解决重复的实体和边。

我们通过提示对 LLM 施加严格的约束,以防止其错误地将含义相似但实际上并不相同的实体或边归为一类。例如,将“1 型糖尿病”和“2 型糖尿病”、“高血压”和“压力”或“MRI”和“CT 扫描”混淆。

我们对提取出的边进行多次遍历,以解析相似实体并减少边的类型数量。实体和边的解析可以防止形成稀疏的知识图谱,而稀疏的知识图谱在诸如 TransE 之类的标准算法下可能会产生无意义的知识图谱嵌入。

我们的提取方法包含多个步骤,具体步骤如下。每个步骤的具体提示信息请参见附录 A,整个过程如图 1 所示。

4.1 实体与关系抽取

第一阶段以非结构化文本作为输入,并生成一个初始知识图谱,其中包含提取的三元组。我们使用谷歌的 Gemini 2.0 Flash 作为语言模型,通过 DSPy 签名提供结构化输出。第一步接收源文本并提取实体列表。第二步根据源文本和实体列表输出主谓宾关系列表。每一步都对应一个 DSPy 签名,该签名指定语言模型在其文档字符串中应遵循的指令。我们发现这种两步法能更好地确保实体之间的一致性。

4.2 聚合

从每个源文本中提取三元组后,我们收集所有源图中的所有唯一实体和边,并将它们合并成一个单一的图。所有实体和边都已规范化为仅使用小写字母。聚合步骤降低了知识图谱中的冗余。请注意,聚合步骤不需要逻辑逻辑模型 (LLM)。

4.3 实体和边缘分辨率

提取和聚合之后,我们通常会得到一个包含重复或同义实体以及可能冗余边的原始图。解析阶段是我们知识图谱提取方法中的一项关键创新,它将代表同一现实世界实体或概念的节点和边合并。我们的解析过程采用两阶段方法,结合了基于嵌入的聚类和基于 LLM 的去重,以高效处理大型知识图谱。该方法分别应用于实体和边项:首先,对图中的所有项进行聚类。我们使用 S-BERT 获取每个项的语义嵌入,并使用 k-means 算法将其聚类成包含 128 个项的簇。

1. 对于聚类中的每个项目,我们检索语义上最相似的前 k 个项目,其中 k=16,采用融合的 BM25 和语义嵌入方法。
2. 然后,LLM 被提示从该集合中识别完全重复项,考虑时态、复数、大小写、缩写和速记形式的差异。
3. 对于每组重复项,LLM 会选择一个最能体现共同含义的规范代表,类似于 Wikidata 使用的别名。聚类图则跟踪哪些实体属于哪些别名。
4. 从集群中删除该项目及其重复项,并重复步骤 1-3,直到集群中不再有任何项目。

这种方法通过并行处理语义聚类,即使对于非常大的知识图谱也能有效地进行去重。在处理我们最大的 2000 万条数据块数据集时,该方法成功地将“冬季奥林匹克运动会”、“冬季奥运会”和“冬季奥林匹克运动会”等实体整合为一个单一的规范表示。

5 项萃取性能基准

尽管已有少量方法尝试从纯文本中提取知识图谱,但由于缺乏基准测试,很难衡量这项任务的进展。为了解决这个问题,我们提出了节点和边信息度量 (MINE),这是第一个直接衡量知识图谱提取能力的基准测试。

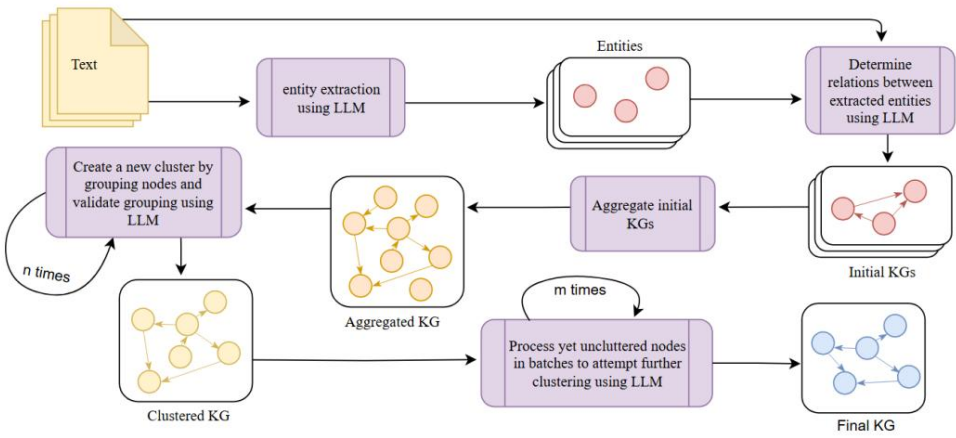


图1:KGen提取方法

知识图谱提取器能够捕获并提炼一段文本,最终形成知识图谱。MINE 包含两个任务:第一个任务评估知识图谱提取器从短篇幅(页面长度)文本中提取信息的能力;第二个任务衡量下游 RAG 在数百万词元数据集上的性能。我们将这两个任务分别称为 MINE-1 和 MINE-2。MINE-1 确保知识图谱提取器能够准确地表示源文本,而 MINE-2 则评估知识图谱在实际应用中的实用性。

5.1 MINE-1:知识保留

MINE-1 近似表示知识图谱提取器能够从文章中捕获的信息比例,而不依赖于下游任务,这可能会掩盖性能提升是源于知识图谱提取器本身还是源于提取过程的某些方面。

MINE-1 数据集包含 100 篇文章,每篇文章都附有 15 个已知存在于文章中的事实。该数据集具有以下特征:文章平均长度为 592 个单词(标准差85 个单词,范围:440-976 个单词),涵盖艺术、文化与社会(24 篇文章)、科学(27 篇文章)、技术(19 篇文章)、心理学/人类经验(18 篇文章)以及历史与文明(17 篇文章)等多个主题。文章由 LLM 生成,以确保在这些领域内实现均衡覆盖。对于每篇文章,MINE-1 使用正在评估的提取器生成相应的知识图谱。

为了评估这些知识图谱的质量,我们使用附录 B 中基于 LLM 的提取提示,从每篇文章中提取 15 个事实。我们手动验证这 15 个事实是否准确且包含在文章中。为了衡量 MINE-1 的性能,知识图谱提取器首先从每篇文章中提取一个知识图谱。然后,MINE-1 包含一个流程,用于验证每个事实是否可以从相应的知识图谱中恢复。

验证过程通过语义查询实现:15 个事实和所有知识图谱节点均使用 SentenceTransformers 的 all-MiniLM-L6-v2 模型进行嵌入。对于每个事实,验证器首先检索知识图谱中语义最相似的前 k 个节点,然后将结果扩展到包含这前 k 个节点的两个关系中的所有节点,这反映了知识图谱通常用于多跳推理任务。由这些节点导出的子图被传递给 LLM,LLM 被提示输出一个二元分数:如果仅从检索到的节点和关系即可推断出该事实,则输出 1,否则输出 0。提示的详细说明见附录 B。知识图谱提取器的最终 MINE-1 分数是15 个事实中得分为 1 的百分比,并对所有 100 篇文章取平均值。虽然基于 LLM 的评估可能引入潜在偏差,但我们通过手动评分60个随机选择的事实-知识图谱对,并将其与 LLM 判断进行比较,验证了其可靠性,结果达到90.2%的一致性和0.80的相关系数。完整的评估流程如图2所示。




图 2:MINE-1 中使用的评估流程

5.2 MINE-2:KG辅助RAG描述

RAG 评估基于 Yang 等人 [2015] 的 WikiQA 数据集,该数据集包含 20,400 个问题,这些问题基于 1,995 篇维基百科文章。使用待评估的方法,我们构建了一个知识图谱 (KG),该图谱聚合了 WikiQA 中所有引用文章的信息。对于数据集中的每个问题,我们使用 SentenceTransformers 中的 all-MiniLM-L6-v2 模型,通过嵌入问题和所有 KG 三元组来检索前 10 个最相关的三元组。然后,我们计算问题与每个三元组之间的余弦相似度,以及 BM25 生成的相关性得分。最终的相似度得分是通过将 BM25 相关性得分和余弦相似度得分进行等权重组合而得到的。我们选择综合得分最高的 10 个三元组,并通过添加 10 个位于前 10 个三元组节点两跳范围内的额外三元组来进一步扩展该集合,从而实现多跳推理。

由于 KGGen 和 GraphRAG 在生成知识图谱时会每个关系链接到一个源文本块,因此我们将检索到的全部 20 个三元组、它们关联的文本块以及原始问题提供给语言模型(LM),由语言模型根据这些输入合成答案。完整的提示信息见附录 B。最后,我们使用 LLM-as-a-Judge 对语言模型的响应进行评估,以确定它们是否包含问题的正确答案。用于此最终验证步骤的提示信息也包含在附录 B 中。OpenIE 不参与其中比较,因为它无法生成将关系链接到原始文本块的知识图谱。

共 6 个结果

我们使用 MINE 对 KGGen 与现有的主流纯文本到知识图谱提取方法进行基准测试,包括: OpenIE (Angeli 等人 [2015])和 GraphRAG (Larson 和 Truitt [2024])。在提供提取保真度的定量比较之后,我们展示了定性结果,证明了KGGen 相对于以往方法的优势。

6.1 对 MINE-1 的评估

图 3 展示了 KGGen、OpenIE 和 GraphRAG 在 MINE 数据集上的准确率。值得注意的是,KGGen 的性能优于其他方法。图 4 展示了来自 MINE-1 的一个查询示例,以及KGGen、OpenIE 和 GraphRAG 提取的相关关系。

6.1.1 跨语言模型的泛化

为了评估 KGGen 在不同基础模型上的鲁棒性,我们使用多种最先进的 LLM 模型在 MINE-1 数据集上测试了其性能。表 1 显示,KGGen在不同的模型上均保持了良好的性能,其中 Claude Sonnet 3.5 模型取得了 73% 的最高分。




图 3:GraphRAG、OpenIE 和 KGGen 的 100 篇文章中 MINE-1 分数的分布。
虚线垂直线表示平均表现。KGGen 的平均得分为66.07% ,显著高于平均水平。
性能优于 GraphRag 47.80% 和 OpenIE 29.84%。

Fact being queried for: "Decentralization provides users with more control over their funds in cryptocurrencies."		
Extractor	Sample of relevant triples queried from KG	Result
KGGen	(cryptocurrencies, enhance, security) (cryptocurrencies, are, decentralized) (cryptocurrencies, provide control over, funds) (cryptocurrencies, enhance, privacy) (cryptocurrencies, operate on, peer-to-peer network) (cryptocurrencies, revolutionizing, transactions) (blockchain, ensures, transparency)	1
GraphRAG	(CRYPTOCURRENCIES, Cryptocurrencies are having a profound impact on the financial world by introducing new ways of thinking about money and finance, FINANCIAL WORLD) (BLOCKCHAIN, Cryptocurrencies operate using blockchain technology which provides a secure and transparent way to record transactions, CRYPTOCURRENCIES)	0
OpenIE	(cryptocurrencies, allowing transactions to occur between users, without need for intermediaries) (cryptocurrencies, allowing, for transactions to occur directly) (Cryptocurrencies, have taken financial world in, storm) (Blockchain, is, ledger technology) (Blockchain, is distributed, ensures)	0

图 4:来自 MINE-1 基准测试的示例查询,以及知识图谱中的相关关系
由 KGGen、GraphRAG 和 OpenIE 提取。请注意,关系三元组是由 KGGen 提取的。
包含正在查询的事实,而 GraphRAG 和 OpenIE 提取的知识图谱则不包含。
KGGen提取的关系类型比其他方法提取的关系类型更简洁,也更容易概括。
GraphRAG 和 OpenIE。这些关系提取自一篇完整的文章,文章全文可在以下位置找到:
附录C。

表1:KGGen的性能比较

(a) KGGen 在 MINE-1 数据集上针对不同语言模型的性能		(b) 不同情况下提取的三元组的有效性方法	
模型	MINE-1 得分 (%)	方法	有效三元组 (%)
克劳德十四行诗 3.5	73	KGGen	98/100 (98%)
GPT-4o	66	GraphRAG	0/100 (0%)
双子座 2.0 闪存	44	OpenIE	55/100 (55%)

KGGen的提取方法能够很好地推广到不同的基础模型中。尽管 Claude Sonnet 3.5 获得了最高的 73% 分数,所有测试模型均保持了合理的提取率。质量,使 KGGen 能够适应用户首选的 LLM 提供商。

6.2 MINE-2 评估:RAG 性能

图 5 显示了 KGen 和 GraphRag 在 MINE-2 上的可比性能。




图 5:KGen 和 GraphRag 在 MINE-2 数据集上的比较。两种方法的性能相当。

6.3 基于人工标注数据的评估:SemEval-2010

为了评估 KGen 相对于人工标注的真实实体提取质量,我们使用 SemEval-2010 Task 8 数据集进行了实验。我们从数据集中随机选取了 100 个句子,每个句子包含两个人工标注的目标实体。在移除实体标记以确保提取结果的公正性后,我们应用 KGen 从每个句子中提取实体及其关系。

我们的评估侧重于实体提取的准确性,因为数据集的关系标签仅包含5个宽泛的类别类型,而非具体的语义关系。我们评估了人工标注的目标实体是否都出现在KGen提取的实体中,从而允许使用更具体的实体描述(例如,“欧亚展览”而非仅“展览”),但这些描述仍然指向同一个对象。

结果显示,KGen 在 96% 的案例中 (96/100) 成功提取了目标实体。与人工标注相比,该方法始终能提取出更详细的实体描述,并且通常能在较长的句子中识别出更多相关实体。例如,对于句子“雄心勃勃的欧亚展览源于阿奇莱·博尼托·奥利瓦的一个想法”,目标实体为“展览”和“想法”,KGen 提取出了 [欧亚展览 , 想法 , 阿奇莱·博尼托·奥利瓦],提供了更具体、更完整的实体识别。

6.4 定性结果

我们首先评估了提取的知识图谱的基本质量,方法是检验提取的三元组是否符合知识图谱的基本定义:主语-谓语-宾语三元组,其中主语和宾语是实体(节点),谓语是关系(边)。我们从每种方法中随机抽取了100个三元组,并手动评估了它们的有效性。结果如表1所示。

尽管 GraphRag 在下游任务上的表现与 KGen 相当,但它提取的结构与传统知识图谱并不十分相似,而这正是 KGen 的一大优势。如图 6b 和 6e 所示,GraphRag 通常只能提取到文章中极少的节点和连接。

这种稀疏性导致关键关系和信息的遗漏。为了便于压缩,图 6a 和 6d 展示了 KGen 为同一篇文章生成的知识图谱的部分内容。图 6c 展示了 OpenIE 知识图谱的诸多问题之一。首先,大多数节点类型都是过于具体、缺乏连贯性的短语。这些节点中有很多是彼此冗余的近乎副本,给图谱增加了不必要的复杂性。此外,如图 6f 所示,OpenIE 主要使用模式匹配来识别实体,并且经常生成诸如“它”和“是”之类的通用节点。由于这些节点出现频率高,它们不包含任何有用信息,却往往成为图中连接最紧密的节点之一。因此,不相关的概念最终仅相隔两跳,并通过诸如“它”或“是”之类的节点连接起来。相比之下,KGen 始终生成信息丰富且连贯的知识图谱,有效地捕捉了文章中的关键关系和信息。




图 6:使用 KGGen、GraphRAG 和 OpenIE 生成的知识图谱的视觉比较。结果显示与 GraphRAG 相比,KGGen 能发现更多信息丰富的节点,从而构建出更丰富的图。并合并同义词,以发现比 OpenIE 更具信息量的图表。

6.5 关于缩放的说明

创建 KGGen 的一个主要动机是生成边类型可泛化的图,以便在语料库规模扩大时可以多次使用。为了测试我们图的可重用性,基于关系,我们从不同大小的文本中生成了三个知识图谱:10000 个字符、100000 个字符。字符数,以及 1,000,000 个字符,并绘制边数除以唯一字符数的曲线。关系。如图 7 所示,KGGen 平均将每种关系类型重复使用10次。每种关系类型的平均出现次数随着语料库规模的增大而增加。相比之下,无论数据大小如何,GraphRAG 平均会将每种关系类型重用2次。图。这表明,随着语料库的增长,GraphRAG 中的关系并不具有普遍性。

6.6 效率和成本分析

为了评估KGGen的实际应用价值,我们分析了其计算效率和成本。在一项大规模提取任务中,我们从帕特里克的小说《风之名》中提取了一个知识图谱。Rothfuss 处理了规模日益增大的文本语料库。表 2 展示了 KGGen 的去重结果。在不同尺度上的有效性。

表 2:KGGen 扩展特征,显示实体和关系去重									
语料库大小 (字符)	预	邮政-	实体	预	邮政-	关系	预	邮政-	边缘
100			1.000			1.000	11 9 9 62 57		1.000
1,000	1	1	0.900	1	1	1.000	498 424		1.000
10,000	20	18	0.867	12	12	0.962	3,180 2,448		0.919
100,000	90	78	0.831	78	75	0.998			0.851
1,000,000	727 4,602	604 3,573	0.776	926 8,137	924 8,094	0.995			0.770

随着规模的扩大,去重率不断提高,这表明我们聚类方法是有效的。算法。对于完整的小说 (100万个字符),KGGen 实现了实体数量减少 22.4%。

通过智能整合,边数减少了 23%。该分析突显了其贡献。
每个模块的提取阶段 (步骤 1-2)从文本中捕获全面的信息,而
解析阶段 (步骤 3)显著降低了冗余度,且未造成信息损失。表 3
列出了处理整部小说的计算成本明细:

表3:KGen处理100万字符语料库的成本和吞吐量分析							
步	及时完成 代币	代币	代币 (s)	总时间吞吐量成本 (代币/秒) (\$)			
KG提取 (步骤1-2)	1.59M 实	0.63M	2.22M	273	0.22M	8,139	0.46
体/边缘解析 (步骤 3)	2.93M	3.15M	279			11,304	0.38
全部的	452万	0.85M	5.37M	551		9,739	0.84

为了进行比较,我们对同一语料库上的 GraphRAG 进行了评估:结果见表 4。

表4:同一语料库上的GraphRAG标度特征				
语料库大小 (字符)	实体	关系	边类型	时间 (秒)
100	2			1.89
1,000	4	1	1	3.01
10,000	16	3	3	29.71
100,000	80	20	20	205.12
1,000,000	514	100	981	2,079.17

虽然 GraphRAG 在短语料库上速度更快,但其执行时间呈超线性增长。
提取时间对比显示出显著差异:GraphRAG 需要 2,319 秒。
仅提取阶段在 100 万字符语料库上的耗时,就比 KGen 的总处理时间短得多。
551 秒 (包括提取和解析)。此外,GraphRAG 的生成速度几乎与
许多关系类型 (966种)对应着许多边 (981条),这表明关系重用率极低,泛化能力较差。
与KGen高效的整合方式相比。

7. 更广泛的影响和社区采纳

我们的工作产生了一种从纯文本中提取知识图谱的工具,有助于解决知识图谱稀缺问题。
改进的知识图谱提取器可能会导致结构化文本的普及,这可以提供帮助。
提高信息检索系统的事实性和可靠性。我们的开源实现
该软件包已获得广泛的社区认可。它在 GitHub 上获得了超过 700 个赞。
该游戏获得星级评价,自发布以来已被下载超过 12,000 次。

8. 局限性和未来工作

尽管KGen相比以往的提取方法具有诸多优势,但其图表仍然存在一些问题。
诸如实体和关系的过度去重或去重不足等问题。对实体进行进一步研究
分辨率的提高可以提升我们知识图谱的质量。此外,我们的基准测试衡量的是语料库……
最多可达 500 万个令牌,但这并不能反映生成网络规模文本所需的规模。
知识图谱基础模型。未来我们基准测试的扩展可以侧重于更大的语料库,以更好地……
衡量不同提取技术的实用性。
领域特定知识提取带来了额外的挑战。例如医学和……等领域。
金融领域需要专门的领域知识,而通用型LLM可能缺乏这些知识,这可能会限制其提取质量,使其无法与人类专家相媲美。MINE-2展示了KGen的能力。
在不同的领域中,融入领域特定的本体可以提高提取精度。
未来的工作可以探索自适应本体集成,以平衡结构与完整性。

致谢与资金披露

我们感谢 NSF 拨款编号 DGE-1656518、NSF 2046795 和 2205329 的支持。
麦克阿瑟基金会、斯坦福大学 HAI 项目和谷歌公司。

参考

Gabor Angeli, Arun Tejasvi Chaganty, Angel X. Chang, Kevin Scott Reschke, Julie Tibshirani, Jean Wu, Osbert Bastani, Keith Siilats 和 Christopher D. Manning. 斯坦福大学 2013 年 kbp 系统。范畴论及其应用, 2013. URL <https://api.semanticscholar.org/CorpusID:14273633>。

Gabor Angeli, Melvin Jose Johnson Premkumar 和 Christopher D. Manning. “利用语言结构进行开放领域信息抽取”。载于 Chengqing Zong 和 Michael Strube 编辑的《第53届计算语言学协会年会暨第7届自然语言处理国际联合会议论文集（第一卷:长篇论文）》, 第 344-354页, 中国北京, 2015年7月。计算语言学协会。doi: 10.3115/v1/P15-1034。网址: <https://aclanthology.org/P15-1034>。

Vahan Arsenyan, Spartak Bughdaryan, Fadi Shaya, Kent Small 和 Davit Shahnazaryan. “用于构建生物医学知识图谱的大型语言模型:从电子病历记录中提取信息”。发表于 2023 年生物医学自然语言处理研讨会。网址: <https://api.semanticscholar.org/CorpusID:256390090>。

安托万·博德斯、尼古拉斯·乌苏尼尔、阿尔贝托·加西亚·杜兰、杰森·韦斯顿和奥克萨娜·雅赫年科。用于建模多关系数据的嵌入转换。载于第 26 届国际神经信息处理系统会议论文集 - 第 2 卷, NIPS 13, 第 2787-2795 页, 美国纽约州雷德胡克, 2013 年。Curran Associates Inc.

Wikidata贡献者。Wikidata:一个免费的协作知识库, 2024。网址:<https://www.wikidata.org>。

Giacomo Domeniconi, Gianluca Moro, Roberto Pasolini 和 Claudio Sartori. “文本分类中术语权重的研究:tf.idf 的一种新型监督变体”。载于第四届数据管理技术与应用国际会议 (DATA 2015) 会议录, 2015 年 7 月。doi :10.5220/0005511900260037。

Junyang Gao, Xian Li, Yifan Ethan Xu, Bunyamin Sisman, Xin Luna Dong 和 Jun Yang. 高效的图谱准确率评估。ACM 信息系统学报, 36(2):1-21, 2018. doi: 10.14778/3342263.3342642. URL <https://dl.acm.org/doi/pdf/10.14778/3342263.3342642>. 杜克大学和亚马逊公司。

何祥楠、邓宽、王翔、李岩、张永东、王萌。Lightgcn:简化和增强用于推荐的图卷积网络。第43届ACM SIGIR信息检索研究与发展国际会议论文集 (SIGIR 20), 第639-648页。ACM, 2020. doi: 10.1145/3397271.3401063. URL <https://doi.org/10.1145/3397271.3401063>。

Nicolas Heist, Sven Hertling 和 Heiko Paulheim. “Kgreat:一个通过下游任务评估知识图谱的框架”。载于第 32 届 ACM 信息与知识管理国际会议 (CIKM 23) 会议录, 第 3938-3942 页。ACM, 2023 年。doi: 10.1145/3583780.3615241。URL: <https://doi.org/10.1145/3583780.3615241>。发布于 2023 年 10 月 21 日。

Subhi Issa, Onaopepo Adekunle, Fayçal Hamdi, Samira Si-Said Cherfi, Michel Dumontier 和 Amrapali Zaveri. 知识图完整性:系统文献综述。IEEE Access, 9: 31322-31339, 2021. doi:10.1109/ACCESS.2021.3056622。网址<https://ieeexplore.ieee.org/document/9344615>。

贾胜斌、项阳、陈晓军、王坤、史佳。知识图谱的三重可信度度量。2019 年万维网大会论文集 (WWW 19), 第 2865-2871 页。ACM, 2019 年 5 月。doi: 10.1145/3308558.3313586. URL <https://doi.org/10.1145/3308558.3313586>。

Vamsi Krishna Kommineni, Birgitta König-Ries 和 Sheeba Samuel. “从人类专家到机器:一种基于 LLM 的本体和知识图谱构建方法”。ArXiv, abs/2403.08345, 2024。URL: <https://api.semanticscholar.org/CorpusID:268379482>。

乔纳森·拉森和史蒂文·特鲁伊特。
2024 年 私人 数据。
2 月 13 日发布的微软研究院博客。

Graphrag:解锁 nar 上的 llm 发现功能- <https://www.microsoft.com/en-us/research/blog/rative-graphrag-unlocking-llm-discovery-on-narrative-private-data/>,

Jens Lehmann,Robert Isele,Max Jakob,Anja Jentzsch,Dimitris Kontokostas,Pablo N. Mendes,Sebastian Hellmann, Mohamed Morsey,Patrick van Kleef,Sören Auer 和 Christian Bizer。
DBpedia – 从维基百科提取的大规模多语言知识库。语义网杂志,6(2):167–195,2015。doi: 10.3233/SW-140。

Yankai Lin,Zhiyuan Liu,Maosong Sun,Yang Liu 和 Xuan Zhu. 学习实体和关系嵌入以进行知识图谱补全。载于第二十九届 AAAI 人工智能大会论文集 (AAAI 15),第 2181–2187 页。AAAI 出版社,2015 年。ISBN 0262511290。

Alexander Maedche 和 Steffen Staab. 面向语义网的本体学习。IEEE Intelligent Systems, 16:72–79, 03 2001. doi: 10.1109/5254.920602。

Idza Aisara Norabid 和 Fariza Fauzi. 基于规则的多模态知识图谱文本提取。
国际高级计算机科学与应用杂志,2022 年。网址: <https://api.semanticscholar.org/CorpusID:249304784>。

Prakhar Ojha 和 Partha Talukdar. KGEval:自动构建知识图谱的准确性估计。载于 Martha Palmer,Rebecca Hwa 和 Sebastian Riedel 编辑的《2017 年自然语言处理实证方法会议论文集》,第 1741–1750 页,丹麦哥本哈根,2017 年 9 月。计算语言学协会。doi: 10.18653/v1/D17-1183。网址: <https://aclanthology.org/D17-1183/>。

Sergio Oramas,Mohamed Sordo 和 Luis Espinosa-Anke。“一种基于规则的音乐片段关系提取方法”。载于《第24届 万维网国际会议论文集》(WWW 15 Companion),第661-666页,美国纽约,2015年。美国计算机协会 (ACM)。ISBN 9781450334730。doi: 10.1145/2740908.2741709。URL:<https://doi.org/10.1145/2740908.2741709>。

齐一帆、郑卫国、洪亮、邹磊. 基于优化人机协作的知识图谱准确性评估. 第28届ACM SIGKDD知识发现与数据挖掘会议 (KDD 22) 论文集,第1368-1378页. ACM,2022. doi: 10.1145/3534678.3539233. URL <https://doi.org/10.1145/3534678.3539233>.

乔斌,邹志良,黄玉荣,王步岳,于长龙.基于BERT的实体与关系抽取联合模型. 神经计算与应用, 34(5):3471–3483, 2022. ISSN 1433-3058. doi: 10.1007/s00521-021-05815-z. URL <https://doi.org/10.1007/s00521-021-05815-z>.

爱德华·W·施耐德。《课程模块化应用:界面系统及其对序列控制和数据分析的影响》。1973年4月,伊利诺伊州芝加哥,教学系统发展协会 (ADIS)会议。1972年4月发表。

Phillip Schneider,Tim Schopf,Juraj Vladika,Mikhail Galkin,Elena Simperl 和 Florian Matthes。 “自然语言处理中知识图谱的十年:一项调查”。载于《ACL亚太分会第二届会议暨第十二届国际自然语言处理联合会议论文集》(AACL-IJCNLP 2022),2022年11月。doi: 10.18653/v1/2022.aacl-main.46。

Kartik Shenoy,Filip Ilievski,Daniel Garijo,Daniel Schwabe 和 Pedro Szekely。“维基数据质量研究”。《网络语义学杂志》,社区知识库特刊,2021 年 6 月。doi:10.48550/arXiv.2107.00156。

Fabian M. Suchanek,Gjergji Kasneci 和 Gerhard Weikum。“Yago:语义知识的核心”。载于第 16 届万维网国际会议论文集 (WWW 07),第 697–706 页,美国纽约,2007 年。美国计算机协会 (ACM)。ISBN 9781595936547。doi: 10.1145/1242572.1242667。URL: <https://doi.org/10.1145/1242572.1242667>。

谭家军、王栋、孙景宇、刘子熙、李晓若、冯阳. 基于差异化测试的知识图谱质量评估. 在线发表,正式版本,2024.

URL <https://doi.org/10.1016/j.jss.2024.07.005>. 2023年10月3日收到, 2024年6月15日修改,2024年6月26日接受,2024年6月29日在线发布。

Jiannan Wang, Tim Kraska, Michael J. Franklin 和 Jianhua Feng. Crowder:众包实体解析. Proc. VLDB Endow., 5(11):1483–1494, 2012 年 7 月. ISSN 2150-8097. doi: 10.14778/2350229.2350263. URL <https://doi.org/10.14778/2350229.2350263>.

薛炳聪、邹磊. 知识图谱质量管理:一项综合调查. IEEE知识与数据工程学报, 35(5):4969–4988, 2023年5月. ISSN 1041-4347. doi: 10.1109/TKDE.2022.3150080. URL <https://doi.org/10.1109/TKDE.2022.3150080>.

发布于2022年2月10日。

Yi Yang, Wen-tau Yih 和 Christopher Meek. “WikiQA:开放领域问答挑战数据集”。载于 Lluís Màrquez, Chris Callison-Burch 和 Jian Su 编辑的《2015 年自然语言处理实证方法会议论文集》,第 2013-2018 页,葡萄牙里斯本, 2015 年 9 月. 计算语言学协会. doi:10.18653/v1/D15-1237。

URL <https://aclanthology.org/D15-1237/>。

Bowen Zhang 和 Harold Soh. 提取、定义、规范化:基于 llm 的知识图谱构建框架. 发表于 2024 年自然语言处理实证方法会议。

URL <https://api.semanticscholar.org/CorpusID:268987666>。

Ruiqi Zhu, Alan Bundy, Jeff Pan, Kwabena Nuamah, Fangrong Wang, Xue Li, Lei Xu 和 Stefano Mauceri. “通过链接预测任务评估知识图谱的质量”。载于第七届自然语言处理与信息检索国际会议 (NLPPIR 2023)论文集,第 1-10 页,韩国首尔,2023 年 12 月. ACM. doi: 10.1145/3639233.3639357. URL: <https://doi.org/10.1145/3639233.3639357>。英国爱丁堡大学信息学院;华为爱尔兰研究中心,爱尔兰。

KG提取提示

本节提供了从文本中提取 KG 的确切提示。
初始 KG 是通过以下两个提示作为 DSPy 签名描述传递而提取的。

提取实体提示 :从源文本中提取关键实体。提取的实体是主语或宾语。这是一项提取任务,请务必认真、准确地参考原文。

文本。

提取关系提示 :从源文本中提取主语-谓语-宾语三元组。主语和宾语必须来自实体列表。

所提供的实体此前均提取自同一源文本。这是一项提取任务,请务必做到详尽、准确,并忠实于参考文本。

从每个文本单元中提取实体和关系后,我们开始去重过程,该过程使用以下提示执行。

提示进行实体或边解析:查找与项目类型相同的 {item_type},
并找到一个最能代表这些重复项的别名。重复项是指含义相同的项,例如时态、复数形式、词干形式、大小写、缩写或简写形式有所不同。如果存在重复项,则返回空列表。

没有任何。

B 提示 MINE

本节提供 MINE 用于评估知识点的 LLM 提示。

从文章中提取事实的提示:从以下文本中提取 15 条描述一个物体与另一个物体之间关系的基本信息。用简短的句子呈现这些信息,并且不要包含文本中未直接出现的信息。你的输出应采用 [info1 , info2 , info15] 的形式。

请确保这些字符串是有效的 Python 字符串。

提示判断查询结果中是否包含某个事实:
角色:您是一名评估员,负责检查正确答案是否可以……
根据上下文信息推断得出。
任务:判断上下文是否包含所述信息。
正确答案。
如果是,请回答“1”;如果不是,请回答“0”。无需任何解释,只需回答数字即可。

RAG 回答提示:使用以下知识图谱三元组和文本证据回答问题。

三元组:{triples_text}

文本证据:{text_block}

问题:{query} 答案:

评估 WikiQA 答案包含性的提示:您是一名事实核查助理。问题:问题;预期答案:预期;模型的响应:响应;模型的响应是否包含预期答案中的信息?

请用一个词回答:是或否。

来自 MINE 的 C 示例文章

本节提供示例事实所在的文章。

标题:加密货币的崛起

内容:近年来,加密货币席卷金融界,彻底改变了我们对货币和交易的认知。从2009年由一位名为中本聪 (Satoshi Nakamoto)的匿名人士或团体创建比特币,到此后涌现的数千种其他加密货币,加密货币已成为全球经济中不可或缺的一部分。推动加密货币崛起的关键因素之一是这些数字资产的去中心化特性。与受政府和中央银行控制的法定货币不同,加密货币运行于点对点网络之上,允许用户之间直接进行交易,无需中介机构。这种去中心化不仅赋予用户对其资金更大的控制权,也增强了安全性和隐私性。推动加密货币流行的另一个重要因素是支撑其运行的技术——区块链。

区块链是一种分布式账本技术,它确保了网络上交易的透明性和不可篡改性。每笔交易都会被记录在一个区块中,并与前一个区块链接,形成一条区块链,一旦经过网络验证,便无法更改。这项技术在建立人们对加密货币的信任和信心方面发挥了重要作用,因为它消除了对可信第三方监督交易的需求。去中心化和区块链技术的概念也为数字货币以外的各种应用铺平了道路。例如,智能合约是一种自动执行的合约,其协议条款直接写入代码。当满足预定义的条件时,这些合约会自动执行,从而无需中介机构,并简化了各个行业的流程。加密货币也因其普惠金融方面的潜力而备受关注。在世界许多地区,传统银行服务对相当一部分人来说难以获得或成本过高。加密货币为个人提供了一种无需传统银行账户即可获得金融服务 (例如转账和支付)的方式。这带来了……

加密货币具有赋能弱势群体并推动经济增长的潜力。其波动性吸引了寻求高回报的投资者和希望从价格波动中获利的投机者。某些加密货币 (例如比特币)的快速升值引发了散户和机构投资者的浓厚兴趣。尽管如此,

波动性既带来盈利机会,也带来风险,因为价格可能在短时间内剧烈波动。监管一直是加密货币领域的一个争议性问题,各国政府和监管机构都在努力寻找监管这一新兴资产类别的方法。

一些国家已经接受了加密货币和区块链技术,认识到它们在创新和经济增长方面的潜力。而另一些国家则采取了更为谨慎的态度,担忧洗钱、逃税和消费者权益保护等问题。尽管加密货币面临诸多挑战和不确定性,但其崛起势不可挡。随着越来越多的个人和企业采用数字货币进行交易和投资,金融格局正在迅速演变。加密货币的未来仍然充满不确定性,但它们对金融世界的影响已经十分深远。总而言之,加密货币的崛起可归因于其去中心化特性、区块链技术、普惠金融潜力、投资机会以及监管挑战。随着这些数字资产不断被接受和采用,它们正在重塑我们对货币和金融的认知。加密货币最终会成为主流还是继续游离于金融体系之外,目前尚待观察,但其影响毋庸置疑,并且很可能在未来几年继续扩大。

D 附加图表




图 7:随着图规模的增加,KGGen 倾向于更频繁地重用每个唯一的类型,而 GraphRAG 无论图规模如何,都保持每个关系类型约 2 个实例的平均使用量。

NeurIPS论文检查清单

1. 索赔

问题:摘要和引言中提出的主要论点是否准确反映了论文的贡献和范围?

答案: [\[是\]](#)

理由:我们支持摘要中提出的所有主张:我们构建了一个知识图谱提取器,并将其性能与现有的知识图谱提取器进行了基准测试。

指南:

·答案“NA”表示摘要和引言中未包含权利要求。

·用纸做的。

摘要和/或引言应清晰阐述论文提出的论点,包括论文的贡献、重要假设和局限性。对此问题的回答为“否”或“不适用”将不会受到审稿人的好评。

·所提出的论断应与理论和实验结果相符,并反映出这些结果在其他情境中的适用范围。·将抱负性目标作为动机是可以的,只要明确这些目标与研究目的的相关即可。

本文未能得出这些结论。

2. 局限性

问题:该论文是否讨论了作者所做工作的局限性?

答案: [\[是\]](#)

理由:我们加入了限制条件部分。

指南:

·答案“NA”表示该论文没有限制,而答案“No”表示该论文没有限制。

·该论文存在一些局限性,但论文中并未讨论这些局限性。

·鼓励作者在论文中单独设立“局限性”章节。论文应指出所有强假设,并说明结果对这些假设违背的稳健性(例如,独立性假设、无噪声环境、模型设定良好、渐近近似仅在局部成立)。作者应考虑这些假设在实践中可能如何被违背,以及由此会产生哪些影响。

作者应反思其论断的适用范围,例如,该方法是否仅在少数数据集或少数几次运行中进行了测试。一般来说,实证结果往往依赖于一些隐含假设,这些假设应该明确阐述。

·作者应该思考影响该方法性能的因素。

·例如,当图像分辨率低或在光线不足的环境下拍摄时,人脸识别算法的性能可能不佳。或者,语音转文本系统可能无法可靠地为在线讲座提供字幕,因为它无法处理技术术语。

·作者应讨论所提出的算法的计算效率以及它们如何随数据集大小而扩展。

·如适用,作者应讨论其方法在解决隐私和公平性问题方面可能存在的局限性。虽然作者可能担心,坦诚地说明局限性可能会被审稿人用作拒稿理由,但更糟糕的情况可能

是审稿人发现论文中未提及的局限性。作者应运用最佳判断力,并认识到,个人为提高透明度而采取的行动在建立维护社群完整性的规范方面发挥着重要作用。审稿人将被明确指示不得因作者坦诚说明局限性而对其进行惩罚。

3. 理论假设和证明

问题:对于每个理论结果,论文是否提供了完整的假设集和完整的(且正确的)证明?

答案: [\[不适用\]](#)

理由:本文不提出任何理论主张。

指南:

- 答案“NA”表示论文不包含理论结果。论文中的所有定理、公式和证明都应编号并交叉引用。

已引用。

- 所有假设都应在定理陈述中明确说明或引用。
- 证明可以出现在正文或补充材料中,但如果出现在补充材料中,鼓励作者提供简短的证明概要以帮助理解。

- 反之,论文正文中提供的任何非正式证明都应在附录或补充材料中提供正式证明。

- 证明所依据的定理和引理应正确引用。

4.实验结果的可重复性

问题:论文是否充分披露了重现论文主要实验结果所需的所有信息,以至于影响到论文的主要论点和/或结论(无论是否提供代码和数据)?

答案: [\[是\]](#)

理由:我们清楚地描述了所有方法,并将在最终版本中发布代码以及用于执行知识图谱提取的 Python 模块。

指南:

- 答案为“NA”表示论文不包含实验。如果论文包含实验,对此问题的回答为“否”将不会受到审稿人的好评:无论是否提供代码和数据,确保论文的可复现性都至关重要。

- 如果贡献内容是数据集和/或模型,作者应描述所采取的步骤。

使他们的研究结果可重复或可验证。

- 根据贡献的不同,可重复性可以通过多种方式实现。

例如,如果贡献的是一种新颖的架构,完整描述该架构可能就足够了;如果贡献的是一个具体的模型和实证评估,则可能需要确保其他人能够使用相同的数据集复现该模型,或者提供模型的访问权限。通常,发布代码和数据是实现这一目标的好方法,但也可以通过提供详细的复现结果说明、提供托管模型的访问权限(例如,对于大型语言模型)、发布模型检查点或其他适合所进行研究的方法来实现可复现性。虽然 NeurIPS 不要求发布代码,但会议要求所有提交的论文都必须提供合理的复现途径,这可能取决于贡献的性质。例如:(a)如果贡献主要是一种新算法,论文应明确说明如何实现该算法。

重现该算法。

- (b)如果贡献主要在于一种新的模型架构,则论文应清晰完整地描述该架构。(c)如果贡献在于一个新的模型(例如,一个大型语言模型),则应提供访问该模型以

复现结果的方法,或者提供复现该模型的方法(例如,使用开源数据集或构建数据集的说明)。

- (d)我们认识到,在某些情况下,可重复性可能比较棘手,在这种情况下,欢迎作者描述他们提供可重复性的具体方法。

对于闭源模型,对模型的访问可能受到某种限制(例如,仅限注册用户),但其他研究人员应该能够找到某种途径来重现或验证结果。

5.数据和代码的开放获取问题:该论文是否提供

了开放获取的数据和代码,并提供了足够的说明,以便忠实地重现补充材料中描述的主要实验结果?

答案: [是]

理由:我们将在补充材料中提供代码,并将所有代码公开发布。

指南:

- 答案“NA”表示该论文不包含需要代码的实验。·更多详情请参阅 NeurIPS 代码和数据提交指南(<https://nips.cc/public/guides/CodeSubmissionPolicy>)。·我们鼓励发布代码和数据,但也理解这可能难以实现,因此“否”是一个可以接受的答案。论文不能仅仅因为未包含代码而被拒稿,除非代码是论文贡献的核心(例如,用于开发新的开源基准测试)。

·说明中应包含复现结果所需的确切命令和运行环境。·更多详情请参阅 NeurIPS 代码和数据提交指南(<https://nips.cc/public/guides/CodeSubmissionPolicy>)。·作者应提供数据访问和准备说明,包括如何访问原始数据、预处理数据、中间数据和生成数据等。·作者应提供脚本以复现新提出的方法和基线方法的所有实验结果。·如果只有部分实验可复现,则应说明脚本中省略了哪些实验以及原因。

·提交时,为保护匿名性,作者应发布匿名化信息。
·版本(如适用)。

·建议在补充材料(论文附件)中提供尽可能多的信息,但允许包含数据和代码的 URL。

6.实验设置/细节

问题:论文是否详细说明了理解结果所需的所有训练和测试细节(例如,数据划分、超参数、它们的选择方式、优化器类型等)?

答案: [是]

理由:我们提供了所有必要的信息,以便可以重复实验。

指南:

- 答案为“NA”表示论文中未包含实验部分。·实验设置应在论文正文中详细阐述。

·这是理解和接受结果所必需的。

·完整的详细信息可以与代码一起提供,也可以放在附录中,或者作为补充材料提供。
·材料。

7.实验统计显著性

问题:论文中是否以适当且正确的方式报告了误差线或其他有关实验统计显著性的适当信息?

答案: [是]

理由:我们会尽可能地报告结果的统计误差范围。

指南:

- 答案“NA”表示该论文未包含实验。·如果结果附有误差线、置信区间或统计显著性检验,作者应回答“是”,至少对于支持论文主要论点的实验应如此。

·应明确说明误差线所反映的变异因素(例如,训练/测试集划分、初始化、某些参数的随机抽取,或在给定实验条件下的整体运行)。·应解释误差线的计算方法(封闭形式的公式、调用库函数、自助法等)。

- 应给出所做的假设(例如,误差服从正态分布)。

- 应明确指出误差线代表的是标准差还是标准误差均值。

- 可以报告 1σ 误差线,但必须明确说明。如果误差正态性假设未得到验证,作者最好报告 2σ 误差线,而不是声称其置信区间为 96%。对于非对称分布,作者应注意避免在表格或图表中显示对称误差线,以免导致结果超出范围(例如,出现负误差率)。

- 如果表格或图表中报告了误差线,作者应在正文中解释误差线的计算方法,并在正文中引用相应的图表。

8.实验计算资源

问题:对于每个实验,论文是否提供了足够的信息,说明重现实验所需的计算机资源(计算工作者类型、内存、执行时间)?

答案: [\[是\]](#)

理由:我们的实验不需要特殊硬件,可以在大多数配备生产模型的笔记本电脑上运行。它们只需要模型提供商提供的 API 密钥。这一点在论文中已明确说明。

指南:

- 答案为“NA”表示论文中未包含实验。论文应注明计算工作节点的类型,例如 CPU 或 GPU、内部集群等。
- 或云服务提供商,包括相关的内存和存储。
- 论文应提供每次实验运行所需的计算量,并估算总计算量。论文应披露整个研究项目所需的计算量是否超过论文中报告的实验所需的计算量(例如,未纳入论文的初步实验或失败实验)。

9.道德准则

问题:本文进行的研究是否在各个方面都符合NeurIPS 道德准则<https://neurips.cc/public/EthicsGuidelines>?

答案: [\[是\]](#)

理由:我们的研究非常符合伦理,没有违反任何 NeurIPS 伦理准则。

指南:

- 答案为“不适用”表示作者尚未审阅NeurIPS道德准则。如果作者回答“否”,则应解释需要审阅NeurIPS道德准则的特殊情况。
- 违反道德准则。
- 作者应确保匿名(例如,如果由于其所在司法管辖区的法律或法规而有特殊考虑)。

10.更广泛的影响

问题:该论文是否讨论了所开展工作的潜在积极社会影响和消极社会影响?

答案: [\[是\]](#)

理由:我们增加了一个更广泛的影响部分。

指南:

- 答案为“不适用(NA)”表示该项工作没有社会影响。如果作者回答“不适用(NA)”或“否”,则应解释其工作为何没有社会影响,或论文为何没有探讨社会影响。
- 负面社会影响的例子包括潜在的恶意或非预期用途(例如,散布虚假信息、生成虚假个人资料、监视)、公平性考虑(例如,部署可能做出对特定群体造成不公平影响的决定的技术)、隐私考虑和安全考虑。

· 本次会议预计许多论文将属于基础研究范畴,而非与特定应用或部署挂钩。然而,如果存在任何直接导致负面应用的途径,作者应予以指出。例如,指出生成模型质量的提升可能被用于生成深度伪造信息是合理的。另一方面,无需指出用于优化神经网络的通用算法可能使人们能够更快地训练生成深度伪造信息的模型。作者应考虑技术按预期使用且运行正常时可能产生的危害,技术按预期使用但产生错误结果时可能产生的危害,以及(有意或无意)滥用技术所造成的危害。

· 如果存在负面的社会影响,作者还可以讨论可能的缓解策略(例如,对模型进行分阶段发布、提供防御措施以应对攻击、建立滥用监控机制、建立系统如何从反馈中学习的机制、提高机器学习的效率和可访问性)。

11. 保障措施问题:该

论文是否描述了为负责任地发布有较高滥用风险的数据或模型(例如,预训练语言模型、图像生成器或抓取的数据集)而采取的保障措施?

答案: [不适用]

理由:我们不发布新模型或敏感数据。我们的代码主要使用现有数据,仅发布少量经验证无害的新数据。

指南:

- 答案“不适用”表示该论文不存在此类风险。· 对于存在高滥用或双重使用风险的已发布模型,应采取必要的安全措施,以确保模型的受控使用,例如要求用户遵守使用指南或访问限制,或实施安全过滤器。
- 从互联网抓取的数据集可能存在安全风险。作者应该说明他们是如何避免发布不安全图片的。
- 我们认识到提供有效的保障措施是一项挑战,而且许多论文也不要求这样做,但我们鼓励作者考虑到这一点,并尽最大努力。

12. 现有资产的许可

问题:论文中使用的资产(例如代码、数据、模型)的创建者或原始所有者是否已得到适当的署名?许可和使用条款是否已明确提及并得到适当的遵守?

答案: [是]

理由:我们对所有使用我们代码或创意的人都予以注明。

指南:

- 答案为“NA”表示该论文未使用现有资源。· 作者应引用生成代码包或数据集的原始论文。作者应说明所使用的资源版本,并尽可能提供……
- 网址。
- 每个资源都应包含许可协议名称(例如 CC-BY 4.0)。· 对于从特定来源(例如网站)抓取的数据,应提供该来源的版权信息和服务条款。如果资源已发布,则应在软件包中提供许可协议、版权信息和使用条款。常用数据集请访问 paperswithcode.com/datasets。他们为部分数据集制定了许可协议。他们的许可指南可以帮助确定数据集的许可协议。
- 对于重新打包的现有数据集,应同时提供原始许可证和衍生资产的许可证(如果已更改)。

·如果网上找不到相关信息,建议作者联系该资源的创建者。

13.新资产

问题:文件中引入的新资产是否有完善的文档记录,并且这些文档是否与资产一起提供?

答案: [是]

理由:我们的资产包括我们新软件包和数据集的详尽文档,这些文档将与最终论文一起发布。

指南:

· 答案为“NA”表示该论文不发布新的资源。研究人员应通过结构化模板在提交的论文中详细说明数据集/代码/模型的信息,包括训练、许可、限制等。

·该论文应探讨是否以及如何获得相关人员的同意。
资产已使用。

·提交时,请记得对您的资源进行匿名化处理(如适用)。您可以创建匿名化的URL或包含匿名化的zip文件。

14.众包和人体受试者研究

问题:对于涉及人类受试者的众包实验和研究,论文是否包含提供给参与者的完整说明文本和屏幕截图(如适用),以及相关补偿(如有)的详细信息?

答案: [不适用]

理由:我们不采用众包模式。

指南:

·答案“NA”表示该论文不涉及众包或研究。
人类受试者。

·将这些信息包含在补充材料中是可以的,但如果论文的主要贡献涉及人类受试者,则应在正文中尽可能详细地描述这些信息。·根据NeurIPS伦理守则,参与数据收集、整理或其他相关工作的劳动者应至少获得数据收集所在国的最低工资。

15.涉及人体研究的机构审查委员会(IRB)批准或同等批准

问题:论文

是否描述了研究参与者可能面临的风险,是否向受试者披露了这些风险,以及是否获得了机构审查委员会(IRB)的批准(或根据您所在国家或机构的要求获得的同等批准/审查)?

答案: [不适用]。

理由:我们没有人体试验对象,因此不需要伦理审查委员会的批准。

指南:

·答案“NA”表示该论文不涉及众包或研究。
人类受试者。

·根据研究开展所在国家/地区的规定,任何涉及人体受试者的研究都可能需要获得伦理审查委员会(IRB)的批准(或同等资格)。如果您已获得伦理审查委员会的批准,则应在论文中明确说明。

·我们认识到,不同机构和地区的程序可能存在很大差异,我们希望作者遵守 NeurIPS 道德规范和其所在机构的指导方针。

·对于初次提交,请勿包含任何可能泄露匿名性的信息(如适用),例如进行审查的机构。

16.法学硕士使用声明

问题:如果LLM是本研究核心方法的重要组成部分、原创性或非标准组成部分,论文是否需要描述其使用情况?请注意,如果LLM仅用于写作、编辑或格式化目的,且不影响研究的核心方法、科学严谨性或原创性,则无需声明。

答案: [\[是\]](#)

理由:我们在方法论中非常清楚地描述了LLM的作用。

指南:

- 答案为“NA”表示本研究的核心方法开发尚未完成

- 将 LLM 作为任何重要的、原创的或非标准的组件。

- 请参阅我们的LLM政策 (<https://neurips.cc/Conferences/2025/LLM>)

- 哪些内容应该描述,哪些内容不应该描述。