

作为一家图书馆，美国国家医学图书馆 (NLM) 提供科学文献的访问途径。收录于 NLM 数据库并不代表 NLM 或美国国立卫生研究院 (NIH) 对文献内容的认可或同意。
了解更多信息：[PMC 免责声明](#) | [PMC 版权声明](#)



医学互联网研究杂志。2025 年 3 月 27 日；27：e65537。号码：[10.2196/65537](#)

基于多中心临床数据库的脓毒症护理大型语言模型驱动知识图谱构建：开发与可用性研究

[杨浩](#)^{1, 2, 3, #}, [李嘉熙](#)^{4, #}, [张驰](#)¹, [Alejandro Pazos Sierra](#)⁵, [沉百荣](#)^{6, ✉}

编辑：阿玛丽莉丝·马夫拉加尼

审核人：曾思航、Gheorghe Cosmin Silaghi、颜文英

[作者信息](#) [文章注释](#) [版权和许可信息](#)

PMCID: PMC11986385 PMID: [40146985](#)

抽象的

背景

脓毒症是一种复杂的、危及生命的疾病，其显著的异质性和海量的非结构化数据给传统的知识图谱构建方法带来了巨大挑战。将大型语言模型（LLM）与真实世界数据相结合，为应对这些挑战、加深对脓毒症的理解和管理提供了一条很有前景的途径。

客观的

本研究旨在利用机器学习模型（特别是GPT-4.0）的功能，结合多中心临床数据库，构建一个全面的脓毒症知识图谱。目标是加深对脓毒症的理解，并为临床决策提供可操作的见解。我们还建立了一个多中心脓毒症数据库（MSD）来支持这项工作。

方法

我们收集了来自中国西部三家主要医院的临床指南、公共数据库和真实世界数据，涵盖了10544例脓症患者。利用GPT-4.0，我们采用先进的提示工程技术进行实体识别和关系抽取，从而构建了一个细致入微的脓毒症知识图谱。

结果

我们建立了一个包含10544例患者记录的脓毒症数据库，其中8497例来自华西医院，690例来自上锦医院，357例来自天府医院。该脓毒症知识图谱包含1894个节点和2021个不同的关系，涵盖9个实体概念（疾病、症状、生物标志物、影像学检查等）和8个语义关系（并发症、推荐药物、实验室检查等）。GPT-4.0在实体识别和关系抽取方面表现出色，在脓毒症专用数据集上取得了76.76的F1分数，优于其他模型，例如Qwen2（43.77）和Llama3（48.39）。在 CMeEE 数据集

上，GPT-4.0 使用少样本学习方法取得了65.42 的 $F1_{\text{分数}}$ ，超过了 BERT-CRF (62.11) 和 Med-BERT (60.66) 等传统模型。在此基础上，我们构建了一个包含 1894 个节点和 2021 个不同关系的综合性脓毒症知识图谱。

结论

本研究开创性地利用逻辑逻辑模型（LLM），特别是GPT-4.0，构建了一个全面的脓毒症知识图谱。创新性地应用了提示工程技术，并整合了多中心真实世界数据，显著提高了知识图谱构建的效率和准确性。最终构建的知识图谱为理解脓毒症、支持临床决策和促进后续研究提供了强大的框架。该方法的成功凸显了逻辑逻辑模型在医学研究中的巨大潜力，并为未来脓毒症及其他复杂疾病的研究树立了新的标杆。

关键词：脓毒症、知识图谱、大型语言模型、提示工程、现实世界、GPT-4.0

介绍

脓毒症是一种危及生命的疾病，可导致患者出现脓毒性休克和多器官功能障碍综合征，通常由严重创伤、手术或感染引起[1]。尽管诊断、治疗和患者监测方面取得了进展，但脓毒症的发病率和死亡率仍然居高不下，构成全球性的医学挑战。每年，全球有超过4900万人罹患脓毒症，约1100万人死亡，死亡率在15%至25%之间波动[2]。这凸显了对脓毒症进行全面研究以改进预防和治疗方法的必要性。近年来，研究日益集中于了解其发病机制[3]、临床表现[4]和治疗方法[5]。然而，脓毒症的复杂性和变异性使得有效治疗和康复策略的开发变得困难。此外，幸存者常常遭受认知功能障碍等长期后遗症[6]，这表明我们对脓毒症后综合征的认识仍存在不足。

构建一个强大的脓毒症专用数据库至关重要。这项举措将显著加强对临床数据挖掘和大数据应用的支持，从而实现海量数据集的聚合和分析。此类进展可为开创性研究奠定基础。此外，构建一

个全面的脓毒症知识图谱[7]也至关重要，因为它将成为数据库深度应用与更深刻理解之间的桥梁。通过将数据库中的详细数据与知识图谱的关联分析能力紧密结合，我们可以更有效地揭示脓毒症的复杂机制，从而推动该领域的深入研究。除了数据库之外，通过整合相关研究的发现、临床表现和治疗方法，该知识图谱可以提供多维、多层次的信息。其目标是深入探究脓毒症的发病机制、临床表现和常规治疗方案，从而更深刻地理解其复杂性。这将为制定更有效的预防和治疗策略提供科学依据，并为临床医生提供实时、全面的参考资料，以便准确评估患者的病情并优化治疗方案。

然而，知识图谱构建中的关系抽取步骤[8]至关重要，它决定了实体间关系的准确性和完整性。目前，基于自然语言处理技术的深度学习模型被广泛用于临床文本实体识别和关系抽取。该过程依赖于专业的数据标注、神经网络模型设计和大样本模型训练，因此耗时耗力。近年来，诸如 GPT-4.0[9]和LLaMA[10]等大型语言模型（LLM）的出现，彻底改变了自然语言处理领域，为解决这一问题提供了新的思路。这些模型能够广泛应用于各种下游任务，例如命名实体识别（NER）[11]和关系抽取[12]。同时，通过提示工程的设计和优化[13]，大型模型处理复杂任务场景的能力得到提升，并在医学领域得到广泛应用[14]。Floridi 和 Chiriatti [15] 评估了多个预训练和微调的大型语言模型（LLM）从疫苗不良事件报告系统（VAERS）记录中提取不良事件的能力。微调后的不良事件 LLM 取得了令人瞩目的平均微F1分数 0.704，展现了 LLM 在自然语言处理任务中的潜力。Hu 等人 [11] 评估了 ChatGPT 执行 2010 年 i2b2 挑战赛定义的零样本临床命名实体识别 [15] 和 Bio-Clinical BERT（基于 Transformer 的双向编码器表示）[16] 的模型进行了比较。结果表明，虽然 ChatGPT 的零样本性能不如微调后的 BERT 临床模型，但在放宽匹配标准的情况下，其_{F1}分数达到了 0.628，表明其性能尚可。然而，这些研究也凸显了一些局限性，例如幻觉造成的错误（即产生不准确、无意义或与上下文无关的输出）[17] 和对否定词不敏感[18]。

本研究旨在构建一个多中心脓毒症数据库（MSD），提供更丰富、更多样化的数据集，这对于深入分析和理解脓毒症至关重要。我们利用GPT4.0进行实体识别和关系抽取，旨在构建一个综合性的脓毒症知识图谱，该图谱基于真实世界数据库，并辅以临床指南和相关公共数据库。这个详尽


的知识图谱旨在为临床医生提供全面的参考，帮助他们更好地理解和治疗脓毒症。通过应用这些先进技术，我们力求提高知识图谱的构建质量和效率，为脓毒症的研究和临床管理提供强有力的支持。

方法

数据收集与数据库构建

该数据集来源于中国西部地区几家知名的三级医院，包括四川大学华西医院、上锦医院和天府医院。数据集包含2020年至2023年间确诊为脓毒症的住院患者的记录。纳入标准为：在指定时间段（2020-2023年）内，出院诊断明确包含脓毒症的患者。对于这些患者，我们收集了全面的数据，包括基线人口统计学信息、实验室检查结果以及记录入院和出院详情的电子病历等相关信息，如图1所示。数据库结构以实体关系图（图S1，[多媒体附录1](#)）的形式呈现。在GPT-4模型处理任何电子病历数据之前，所有个人身份信息，例如姓名、地址和患者ID，均按照标准去标识化协议进行移除。这确保了在关系抽取和实体识别过程中不会包含任何可识别的信息。

图1。



[在新标签页中打开](#)

四川大学华西医院、上锦医院和天府医院脓毒症数据集概述（2020-2023 年）。

脓毒症专家共识和指南

整合来自脓毒症专家共识声明和临床指南的数据，有助于建立对该领域最佳实践和最新建议的基础性理解。这些权威来源对构建全面的知识库做出了重要贡献。主要数据来源是PubMed，我们的检索式如下：

（脓毒症[ti] 和指南[pt] 和 2020/01/01:2023/12/01[pdat]）或（脓毒症[ti] 和审查[pt] 和 2020/01/01:2023/12/01[pdat]）

本次检索旨在获取过去三年发表的所有关于脓毒症的专家指南和文献综述，作为后续关系提取的重要知识库。为了实现从PubMed数据库自动检索文章，我们使用了Biopython库[19]，它提供了一种与PubMed数据库高效交互的方式。此外，我们还整合了来自MetaSepsisBase[16]的生物标志物数据。MetaSepsisBase是一个开放的脓毒症数据库，也是首个脓毒症生物标志物知识库。该数据库包含320种脓毒症生物标志物的生物学信息，其中450条记录来源于PubMed，并通过NCBI基因数据库[17]和HGNC数据库[18]进行了注释。这项工作为构建脓毒症知识图谱奠定了坚实的知识基础。

知识图谱的构建

脓毒症知识图谱的构建过程主要采用基于实体的方法，包括数据预处理、分析、实体构建[20]、知识提取[21]、融合[22]和存储等关键步骤。与传统的知识图谱构建方法不同，本研究利用GPT-4.0对原始数据进行知识提取和初步数据挖掘，从而提高了最终知识图谱的准确性。

构建知识图谱实体

实体构建[23]的主要目标是获取、描述和表示特定领域内的知识，从而促进对脓毒症领域的共同理解。这包括识别广泛接受的术语、提供精确的定义，以及建立它们在不同形式模式层次上的相互关系。在我们的研究中，实体定义及其相互关系分别列于表1和表2中。

表1。

基于中国西部 3 家医院（2020-2023 年）的多中心临床数据（N=10,544），对脓毒症知识图谱中的实体概念进行定义。

数字	概念术语	属性	意义
1	疾病	规范名称、概念 ID、TUI、定义、参考文献和同义词	疾病是一种非典型的生命过程，是由于在特定条件下，身体暴露于病原体损害后，自身调节功能紊乱而发生的。
2	症状	规范名称、概念 ID、TUI、持续时间、严重程度、频率和时间模式	疾病过程中，由于一系列生理、代谢和形态异常，患者出现主观上的非典型感觉或客观上的病理变化。
3	影像检查	规范名称、概念 ID、TUI、类型、身体部位和影像学发现	影像检查是一种用于观察人体内部情况，以进行临床分析和医疗干预的技术。
4	生物标志物	规范名称、概念 ID、TUI、生物标志物类型、参考文献、同义词、临界值、灵敏度和特异性	体内可测量的物质，用于指示生理状态、疾病的存在或疾病的进展。

数字	概念术语	属性	意义
5	实验室测试	规范名称、概念ID、TUI、正常范围、单位和测量值	在实验室进行的物理或化学检验，以确定所提交物质的含量、性质、浓度、数量和其他特性。
6	子类型	规范名称、概念ID、TUI、定义、参考文献和同义词	根据特定特征或特性对类别或组进行细分。例如，疾病亚型可能表明不同的病理特征或症状表现。
7	致病机制	规范名称、概念ID、用户界面 ^b 、类型、感染源、参考文献、生物标志物和指南	导致疾病发生的生物学或生化过程，包括病原体感染和基因突变等因素。
8	药物治疗	规范名称、概念ID、TUI、药物名称、药物类别、剂量、治疗持续时间、不良反应、药物相互作用和制剂	用于预防、治疗和诊断疾病的物质。理论上，药物涵盖能够影响人体器官生理功能和细胞代谢活动的化学物质。
9	外科手术	规范名称、概念ID、TUI（治疗干预措施）、麻醉类型、指南、并发症、恢复时间和级别	手术是指由外科医生或其他专业人员使用器械进入人体或其他生物组织的程序。它涉及施加外力以消除病变、改变组织结构或植入异物。

[在新标签页中打开](#)

TUI

: 类型唯一标识符，表示 UMLS 中概念的语义类别。

^b UI: 唯一标识符，用于在 UMLS 中唯一区分概念或术语。

表2。

基于中国西部 3 家医院（2020-2023 年）的多中心临床数据（N=10,544），对脓毒症数据中的语义关系进行定义。


数字	概念术语	意义
1	并发症	疾病发展可能会引发其他疾病或出现其他症状。
2	有症状	描述疾病与症状之间的相关性。
3	建议的影像检查	推荐对脓毒症患者进行影像学检查。
4	相关生物标志物	与脓毒症相关的生物标志物。
5	对待	与脓毒症相关的外科治疗方式。
6	推荐的实验室检测项目	与脓毒症相关的常规实验室检查。
7	引起	导致脓毒症发生的潜在因素。
8	推荐用药	脓毒症治疗过程中的药物干预。

[在新标签页中打开](#)

知识图谱技术的构建方法通常分为自顶向下和自底向上两种途径[24]。自顶向下途径首先基于逻辑关系和层次结构定义模式层，然后将数据实体映射到该模式（[如图2A所示](#)）。相比之下，自底向上途径则侧重于从各种数据源中提取实体和属性，构建知识图谱的数据层（[如图2B所示](#)）。该

过程整合提取的实体和属性，优化知识图谱的模式层，以便对实体模型进行迭代更新。自顶向下途径确保领域实体包含丰富的专业知识并具有较高的准确性，而自底向上途径则增强了其实用性。鉴于脓毒症的独特性，本研究采用这两种途径构建脓毒症知识图谱。这种双重途径旨在提高知识图谱的教育价值、准确性和实用性。

图2。



[在新标签页中打开](#)

采用自顶向下和自底向上的方法构建脓毒症知识图谱。(A) 模式层：自顶向下的方法基于逻辑关系和层次结构定义结构化的模式层。(B) 数据层：自底向上的方法从各种数据源中提取实体和属性。CRP：C反应蛋白；IL：白细胞介素；PCT：降钙素原；PRO-BNP：B型利钠肽前体（脑钠肽前体）。

快速工程和模型评估

在本研究中，我们采用语言学习模型（LLM）提示工程方法进行知识提取。通过利用GPT-4.0强大的语言理解和模式识别能力，我们引导模型生成脓毒症特异性提示，并提取相关信息。该方法的优势在于，它无需手动指定复杂的规则或模式，即可处理自然语言中复杂的结构和上下文。

与传统知识抽取方法相比，基于语言学习模型（LLM）的方法具有以下几个优势。首先，LLM能够自主学习语言的语法和语义规则，使其更能适应该领域内复杂的表达方式[24]。其次，由于在大规模语料库上进行了预训练，LLM能够获取丰富的背景知识，从而增强其在理解特定领域文本时的上下文感知能力[25]。此外，LLM擅长处理歧义和不清晰的语言表达，提高了知识抽取的鲁棒性[26]。

为了提高我们方法的有效性，我们引入了零样本[27]和少样本[28]学习技术，如文本框1所示。通过在语言模型（LLM）中利用少样本学习，我们使模型即使在样本有限的情况下也能快速适应新的脓毒症相关文本，从而使模型能够灵活地适应特定领域的上下文和语言表达。这为知识抽取过程增加了灵活性和个性化，进一步提高了模型的性能和适应性。为了验证使用GPT-4.0进行提示工程的有效性，我们选择了CMeEE（中文医学实体抽取）公共数据集[29]进行命名实体识别（NER）任务（如图3所示），并通过将其与Med-BERT[30]和LSTM（长短期记忆网络）[31]等传统模型进行比较，建立了基准性能。该比较表明GPT-4.0在处理复杂医学文本方面具有良好的适应性和灵活性，突显了大型语言模型在知识图谱构建方面的潜力。此外，为了评估 GPT-4.0 在

本研究中的识别性能，我们创建了一个专注于脓毒症的数据集。由于人工标注成本高昂，我们请一位医学专家对随机选择的 61 位患者的电子病历 (EMR) 中的命名实体进行标注，标注示例见[多媒体附录 1](#)。我们还通过与其他大型模型（Qwen2 [阿里巴巴云]、Llama3 [Meta AI] 和 ChatGPT 3.5 [OpenAI]）进行比较，进一步评估了 GPT-4.0 在自然语言处理任务中的性能。我们使用 F1 分数评估模型，该分数通过计算真阳性、假阳性和假阴性来反映整体性能，综合考虑了精确率和召回率。F1 分数是精确率和召回率的调和平均值，能够全面衡量模型的有效性。

针对零样本和少样本学习场景中的脓毒症关系提取的提示设计。

提示设计

假设你是一个实体-关系三元组抽取模型。我给你三个列表：头部实体类型（主语类型）、尾部实体类型（宾语类型）和关系列表（关系类型）。给定一个句子，请根据这三个列表抽取句子中的主语和宾语，并组成一个（主语，关系，宾语）形式的三元组。

关系：['临床表现', '手术治疗', '生物标志物', '亚类', '发病机制', '实验室检查', '影像学检查', '并发症', '药物治疗']

给出的句子是\n{三元组列表}

示例（少镜头）

示例 = [

{

“文本”：“在成人中，约有三分之一的急性心力衰竭（AHF）患者可能并发真菌感染，主要由白色念珠菌引起。循环系统问题可能导致窦性心动过缓，心率减慢出现较晚，少数情况下可能发生心脏骤停。”

“三重列表”：[

[“AHF”, “并发症”, “窦性心动过缓”], [“AHF”, “并发症”, “真菌感染”], [“真菌感染”, “生物标志物”, “白色念珠菌”]

]

},

{

“文本”：“胰腺癌，经过4个月的初始治疗后，上腹部超声检查显示胰腺肿块伴肝转移。”

“三重列表”： [


[“胰腺癌”, “临床表现”, “胰腺肿块”], [“胰腺癌”, “影像学检查”, “上腹部超声检查”], [“胰腺癌”, “临床表现”, “肝转移”]

]

}

]

图 3。

[在新标签页中打开](#)


针对医学中文的零样本和少样本命名实体识别任务的提示设计。

知识融合

在我们的研究中，我们使用了来自scispaCy[32]的实体链接器模块，该模块整合了统一医学语言系统（UMLS）[33]术语标准，构建了一个全面的知识库。UMLS有助于术语的对齐，例如将“高血压”映射到标准化概念“高血压疾病（C0020538）”。为了确保有效的文本匹配，我们对不同数据源中的实体名称进行了标准化和清理。这一过程包括统一字母大小写、去除标点符号和处理缩写，从而将“心力衰竭”和“HF”等术语标准化为一致的术语体系。完成初步处理后，我们使用文本相似度算法进行实体匹配，采用基于词嵌入和Jaccard相似度的算法来计算实体名称之间的相似度得分。在对齐过程中，我们设定了0.85的相似度阈值，以确保只有高度相似的实体才能被识别为对应实体。对于相似度值低于阈值的实体，我们保留其原始值，并通过人工审核解决任何潜在的歧义，从而确保最终比对结果的精确性和可信度。这种精心设计的流程不仅提高了实体比对的效率，也保障了我们研究成果的准确性和可靠性。

平台实施

MSD 使用 MySQL 软件（版本 5.7；Oracle 公司）进行数据管理。网页采用 Bootstrap 4.0（Bootstrap 团队）开发，并使用了 Flask 框架。我们使用了多个 JavaScript 插件，例如 Datatable（版本 1.10.10；SpryMedia 公司）和 ECharts（版本 5.0；百度），用于创建数据表和可视化图表。知识存储方面，我们使用了 Neo4j 图数据库 [34]。该图数据库的底层存储原理是利用节点、边和属性来存储图数据。Neo4j 目前被公认为最流行的高性能 NoSQL 图数据库之一 [35]，以其高可用性、稳定性、可扩展性和强大的直观性而著称。本研究结合开源Python库（例如py2neo[36]）和OpenAI接口，实现了知识提取以及关系和节点的添加/修改。具体而言，我们使用了通过应用程序编程接口（API）访问的GPT-4-turbo模型作为人工智能模型，而对于 Scispacy，我们使用了en_core_sci_sm模型。整个研究和构建过程如图4所示。



本研究构建了一个多中心脓毒症知识图谱（n=10,544例脓毒症患者），该研究整合了GPT-4和Neo4j技术。流程图展示了从中国西部三家三级医院（华西医院、上锦医院和天府医院；2020-2023年）收集回顾性数据、通过LLM驱动的实体识别进行多模态数据处理以及图数据库的构建。LLM：大型语言模型；MSD：多中心脓毒症数据库。

伦理考量

本研究已获得四川大学华西医院医学伦理委员会的批准（批准号：2024-126）。本研究对已去标识化的患者数据进行了二次分析，该分析严格遵循数据收集时获得的原始知情同意书，无需再次征得同意即可进行后续分析。为确保参与者的隐私和保密性，所有个人身份信息在分析前均已删除。本研究未向参与者提供任何经济补偿。此外，本稿件不包含任何可能识别个人身份的图像。相关知情同意书已作为补充材料提交。

结果

在本研究中，我们利用来自中国西部三家主要医院的真实世界数据构建了一个多中心脓毒症数据集（MSD）[37]。该数据库涵盖2020年至2023年期间共10544例脓毒症患者。每家医院均贡献了大量患者记录，其中华西医院8497例，上锦医院690例，天府医院357例。该MSD包含全面的数据点，例如基线人口统计学信息、实验室检查结果、电子病历以及详细的入院和出院记录。这一大规模、多中心脓毒症数据集为构建高度详细且具有临床意义的脓毒症知识图谱奠定了坚实的基础。

此外，我们利用GPT-4.0，基于MSD、专家共识和开放数据源进行了实体识别和关系抽取。随后，我们通过与UMLS进行基准测试实现了知识整合。最终，我们在表1和表2中给出了关键实体及其语义关系的定义。表1概述了疾病、症状、生物标志物和影像学检查等关键实体，这些实体对于理

解脓毒症的临床特征至关重要。例如，“症状”实体描述了患者经历的主观和客观体征，而“生物标志物”则代表指示疾病存在或进展的可测量物质。[表2](#)中定义的这些实体之间的关系，有助于深入了解脓毒症的复杂动态。“有症状”和“并发症”等关系展示了特定症状如何与疾病相关联，以及疾病进展如何导致其他健康问题。我们成功构建了一个包含1894个节点和2021个关系的脓毒症综合知识图谱。通过整合实体定义及其相互关系，本研究旨在加深对脓毒症的理解，并为知情的临床决策提供支持，最终有助于改善患者预后。此外，我们还构建了脓毒症本体的相关示例，如图S7所示（见[多媒体附录1](#)）。

然后，我们引入了零样本和少样本方法，以探索模型在处理基于 CMeEE 的未见或罕见实体时的性能，并将其与 BERT-CRF [[34](#)]、BERT-www [[35](#)]、Lattice-LSTM [[36](#)] 和 Med-BERT [[30](#)] 等传统模型进行了比较。结果表明，使用 GPT-4 的少样本方法优于传统模型，*F1*分数达到 65.42，这证明了其在标注数据有限的情况下能够有效地适应新的实体类型。此外，我们构建了一个脓毒症数据集，该数据集包含由医学专家标注的临床记录，以在真实的医疗保健环境中进一步评估模型。比较各模型的性能，GPT-4 取得了显著的*F1*_{分数}，达到 76.76，远超其他语言学习模型（如 Qwen2 和 Llama3），表明其在该专业领域识别关键医学实体方面具有强大的能力。[表3](#)和[表4](#)分别展示了不同模型在 CMeEE 数据集和 Sepsis 数据集上的性能。

表3。

在中文医学实体提取数据集上，对 GPT-4 与 BERT 和 Lattice-LSTM 模型进行零样本和少样本学习性能比较。

模型	CMeEE ^和		
	精确	记起	F1分数
BERT ^b -base	63.08	64.08	62.11
BERT-wwm	61.5	61.29	61.72
格子长短期记忆网络(Lattice-LSTM) ^c	46.34	43.60	49.44
Med-BERT	53.33	47.58	60.66
GPT-4 和零射击	64.07	68.97	59.82
GPT-4 和 Few shot	65.31	64.89	65.73

[在新标签页中打开](#)

CMeEE^和：中文医学实体提取。

^b BERT：来自Transformer的双向编码器表示。

^c LSTM：长短期记忆。

表4。

GPT-4、Qwen2-72B、Llama3-70B 和 GPT-3.5 模型在脓毒症数据集上的性能比较。


模型	脓毒症数据集		
	精确	记起	F1分数
Qwen2-72B	44.73	42.85	43.77
Llama3-70B	49.40	47.43	48.39
GPT-3.5	56.63	54.48	55.53
GPT-4 和 零射击	72.12	70.48	71.29
GPT-4 和 Few shot	77.73	75.81	76.76

[在新标签页中打开](#)

脓毒症的主要并发症

对脓毒症相关并发症的研究在临床研究中具有至关重要的意义。在本研究中，我们从收集的病例和文献中识别出 203 个与并发症相关的节点（[图 5](#)）。我们查询了脓毒症与并发症之间的关系，并通过查询 `MATCH ()-[r:`has complication`]->() RETURN r ORDER BY r.weight DESC LIMIT 10` 进行分析。

图 5。




[在新标签页中打开](#)

通过多中心脓毒症数据库中的加权关系分析确定的前 10 个脓毒症并发症：条形图显示了肺炎（32.1%）、低蛋白血症（28.5%）、脓毒性休克（25.9%）等的患病率。

脓毒症药物统计数据

脓毒症是一种严重的全身性炎症反应，通常由感染引发。在知识图谱中，输入以下代码可以揭示脓毒症最常用药物及其相关并发症之间的关系（[图 6](#)）。使用的查询如下：MATCH p=(n:medication)-[r:`推荐药物`]-() RETURN p order by r.weight ASC limit 25。

图 6。




脓毒症治疗中的药物干预模式：描述药物-并发症关系的弦图（生理盐水、葡萄糖输注等）。

脓毒症症状统计数据

脓毒症被定义为一种全面的全身性炎症反应，其多方面的性质通过对患者观察到的前 25 个症状的统计分析得以揭示（[图 7](#)）。在知识图谱中进行了相关查询，相应的代码为 `MATCH p=()-[r:'has symptom']->() RETURN p order by r.weight asc`。

图 7。




[在新标签页中打开](#)

脓毒症常见症状及其出现频率前 10 项的知识图谱表示。

临床应用

基于脓毒症知识图谱的结果，我们采用GraphRAG[[38](#)]技术辅助大型模型，为临床医生提供更精准的决策支持。与传统的检索增强生成（RAG）技术相比，GraphRAG在处理复杂关系和多步骤推理方面表现卓越，能够提供更全面、更准确的答案。这对于脓毒症等复杂疾病的诊断和治疗尤为重要，因为临床决策通常涉及多个变量和潜在的相互作用。此外，GraphRAG提高了信息检索和定制化摘要生成的效率，使临床医生能够快速获取与患者病情相关的有用信息和建议。效率的提升显著提高了临床决策的准确性，使医生能够在复杂的临床环境中做出更明智的判断。随着计算能力的提升，脓毒症知识图谱与大型模型的整合能够整合来自电子病历、实验室检查、影像学 and 重症监护的数据，从而实现对患者临床特征和评分系统（例如SOFA和APACHE II）的实时分析，帮助医生快速识别不同风险等级的脓毒症患者，并促进早期预警系统的建立。在临床决策过程中，知识图谱、RAG模型和快速工程策略的结合，能够提供基于高质量证据的治疗建议，从而提升决策的科学性和有效性。目前，我们的临床团队已提供了相关的案例研究（详见补充材料），其中包括基于GPT-4的GraphRAG技术实施前后的对比分析。通过使用临床金标准以及 BLEU [[39](#)]、ROUGE-1、ROUGE-2 和 ROUGE-L 指标 [[40](#)]，我们对模型的生成结果进行了比较。其中，BLEU 主要评估生成文本与参考文本之间的词汇重叠度，反映了生成内容的准确性；而 ROUGE 则侧重于召回率，强调生成文本在捕捉参考内容方面的全面性。通过对这些指标的综合分析（[如图 8](#)所示），我们进一步验证了 GraphRAG 在实际应用中的有效性和优势。

图 8。



[在新标签页中打开](#)

对 GraphRAG 技术在脓毒症临床决策支持中实施前后的性能进行比较分析。

讨论

主要发现

本研究旨在利用真实世界的多中心临床数据，开发一个基于大型逻辑逻辑模型（LLM）构建脓毒症知识图谱的框架。核心目标是探索使用LLM技术（特别是GPT-4.0）构建专注于脓毒症的综合性领域特定知识图谱的可行性和有效性。研究结果表明，通过精心的模型优化，GPT-4.0能够从临床数据中准确提取实体和关系，其性能优于BERT和LSTM等传统模型。尤其值得一提的是，GPT-4.0在CMeEE数据集上展现了最佳的少样本性能，F1值达到^{65.42}；在脓毒症数据集上，其F1值高达76.76，优于其他开源模型。这些结果凸显了LLM在数据标注有限的领域构建专业知识图谱的潜力，并强调了LLM无需大量模型重新训练即可跨任务和领域进行适应性训练的优势。

成功构建脓毒症特异性知识图谱标志着知识提取和临床决策支持领域的重大进展。利用 GPT-4.0 的预训练能力，我们能够从通常需要大量领域特定训练的小型数据集中生成有意义的见解。这些发现与其他使用大型模型（例如 GPT-4.0、GPT-3.5、LlaMA [10] 和 SOLAR [41]）进行生物学关系提取的研究结果相一致。特别是，GPT-_{4.0}在从半结构化数据中提取生物学关系方面表现出色，F1分数超过 0.881 [42]，这进一步证实了其在构建医疗保健知识图谱方面的实用性。我们的结果还表明，GPT-4.0 能够快速适应脓毒症等专业领域，并构建医学相关的知识图谱，而无需传统机器学习方法通常所需的大量预处理和数据标注。为了将这些技术进步置于临床应用的背景下进行分析，我们针对已建立的生物学知识基础设施（包括BIOS[17]、PrimeKG[7]和UMLS）进行了比较分析。基准测试揭示了我们以脓毒症为重点的方法的几个关键优势。BIOS优先考虑通过通用语义关系实现全面的本体覆盖[43]，而我们的模型通过上下文感知嵌入实现了更优的临床相关性，从而保留了疾病特异性的病理生理层级。此外，PrimeKG通过分子水平的药物-

靶点相互作用推进精准医疗，而我们的框架整合了多模态临床数据流，包括178个具有时间粒度的脓毒症相关生物标志物，从而实现了现有资源无法实现的动态风险分层。此外，通过与UMLS术语标准的系统性对齐，我们的实现确保了互操作性，同时又不损害领域特异性，从而解决了传统临床知识图谱的一个关键局限性——传统知识图谱要么为了标准化而牺牲粒度，要么反之亦然。

然而，我们构建的脓毒症知识图谱不仅为临床实践提供了宝贵的见解，而且加深了对脓毒症复杂病理生理机制的理解。[如图5](#)所示，该图谱涵盖了肺炎、低蛋白血症、脓毒性休克和心力衰竭等关键并发症。通过捕捉这些关键组成部分，该图谱有助于风险分层和预后预测，最终提高治疗效率。此外，我们的知识图谱还可用于治疗优化。[如图6](#)所示，该系统量化了生理盐水输注、葡萄糖代谢纠正和电解质平衡干预措施之间的动态关系[[41-43](#)]。机器学习模块进一步实现了基于病原体敏感性模式和药代动力学参数的抗菌药物疗效预测建模[[44,45](#)]，并同时通过伤害感受生物标志物追踪镇痛需求[[46](#)]。这种综合方法能够根据不断变化的炎症标志物和器官功能障碍指标实时调整治疗方案。[如图7](#)所示，我们的可视化平台还整合了全面的症状分析。该图的时间映射功能揭示了从初始呼吸系统表现（例如呼吸急促、支气管分泌过多[[47](#)]）到后续多器官受累（包括胃肠动力障碍[[48](#)]、心血管功能受损[[49](#)]、泌尿系统症状[[50](#)]和神经系统恶化[[51](#)]）的进展轨迹。通过将症状群与生物标志物谱和治疗反应关联起来，该系统能够早期发现脓毒症引起的器官衰竭，并为制定个性化干预策略提供决策支持。这种多模态临床数据的系统性整合最终促进了脓毒症管理中精准医疗模式的形成，将病理生理学见解与优化的治疗方案相结合。

尽管结果令人鼓舞，但我们也承认本研究存在一些局限性。GPT-4.0虽然展现出令人印象深刻的实体识别和关系提取能力，但偶尔也会产生错误输出。例如，该模型会为脓毒症推荐不相关的实验室检查（例如“血胆固醇检查”），并错误地归因于某些致病因素，例如“运动引起的脓毒症”。此外，GPT-4.0难以处理传统中医术语的细微语义，例如“阴阳失衡”和“气虚”，从而导致误解。这些错误意义重大，因为它们可能会影响下游的临床应用，例如诊断准确性和治疗决策。然而，GPT-4.0在处理专业医学术语和微妙关系方面的固有局限性凸显了建立健全的人工审核流程以确保知识图谱准确性的重要性。我们已经实施了这样的审核流程来减少错误并维护数据完整性；但是，仍需进一步改进模型以减少对人工干预的依赖。除了这些技术限制外，GPT-4.0在医疗保健领域的

应用也引发了重要的隐私和安全问题[52]。如前所述，我们的研究采取了严格的措施来保护患者数据，包括消除个人身份信息并遵守相关的隐私法规。尽管采取了这些预防措施，使用 GPT-4.0 等商业模型仍然存在数据泄露和敏感患者信息潜在暴露的风险[53]。

在未来的研究中，为确保数据安全，我们计划在安全环境中部署本地化模型，例如 Llama 3.1 和 Qwen 2，从而确保所有数据处理活动均在受控系统内进行。通过这种方式，我们旨在增强数据隐私并降低数据泄露风险，在保障患者隐私的同时，确保知识图谱的完整性。此外，我们计划通过整合 Gemini [54] 和 Claude [55] 等先进模型，进一步优化模型的准确性和上下文理解能力，这些模型有望提供更精确、更具上下文关联性的结果。我们还计划扩展数据集，纳入更多临床和中医相关数据，以进一步增强知识图谱的鲁棒性和适应性。我们将探索诸如低秩自适应 [56] 和 p 值调优 [57] 等微调技术，以提高模型的精确度和效率，确保知识图谱能够捕捉更广泛的医学细微差别。此外，我们将尝试其他提示设计，包括将实体识别任务转换为分类任务[58]或参考Teler分类法[59]，这有望提高模型处理复杂医学关系的能力。作为这项工作的一部分，我们还将生成更多黄金标准数据，以比较各种提示策略对知识图谱准确性的影响。

总之，本研究强调了基于机器学习模型（LLM）的方法，特别是GPT-4.0，在构建准确有效的医学知识图谱方面的潜力，即使在数据匮乏的环境下也能发挥作用。我们开发的脓毒症知识图谱不仅加深了对脓毒症的理解，也展示了LLM驱动方法在构建跨多个医学领域的特定领域知识图谱方面的广泛适用性。随着GPT-4.0等大型模型的不断发展，它们处理和解读复杂医学数据的能力将彻底改变医疗专业人员获取、解读和应用医学知识的方式。该方法的可扩展性和适应性表明其具有在多种疾病领域广泛应用的潜力，为临床实践中的个性化和精准医疗奠定了基础。此外，知识图谱的交互式 and 可视化特性增强了其实用性，为临床医生提供了一个用于研究和日常决策的动态工具。

结论

利用真实世界数据和创新性地应用GPT-4.0等低级逻辑模型（LLM）成功构建的脓毒症数据库（MSD）标志着脓毒症的理解和管理取得了重大突破。通过快速工程构建全面的脓毒症知识图谱，不仅展现了LLM技术在医学研究中的巨大潜力，也突显了其强大的泛化和适应能力。我们的研究结果，特别是少样本模型在实体识别和关系理解方面的卓越性能，凸显了LLM在快速构建专业数据库和知识图谱方面的高效性和成本效益。这种开创性的方法为脓毒症领域乃至其他医学领域的未来研究和数据库开发树立了新的标杆。

致谢

作者衷心感谢吴荣荣博士对图表绘制的指导。我们还要感谢研究组全体成员，他们为本研究做出了宝贵的贡献并进行了深入的讨论。本研究由国家自然科学基金（项目编号：32200545 和 32270690）、四川大学华西医院“1·3·5”学科创新引智计划（项目编号：ZYGD23012 和 ZYAI24044）、成都市医学科研项目（项目编号：2024269）资助，并获得欧盟和西班牙加利西亚自治区政府（竞争性参考组项目，项目编号：ED431C2022/46；GRC）的资助。此外，中信集团-UDC 和 INIBIC 也为本研究提供了支持。

缩写

- 伯特
 - 来自Transformer的双向编码器表示
- CMeEE
 - 中文医学实体提取
- 电子病历
 - 电子病历
- 法学硕士
 - 大型语言模型

LSTM

长短期记忆

默沙东

多中心脓毒症数据库

NER

命名实体识别

抹布

检索增强生成

UMLS

统一医学语言系统

VAERS

疫苗不良事件报告系统

多媒体附录 1

附加信息。

(1.5MB, docx)

[jmir v27i1e65537_app1.docx](#)

数据可用性

为确保数据安全，数据库目前不支持直接在网站上下载。如有需要，研究人员可通过电子邮件联系华西医院疾病系统遗传学研究所所长沈百荣教授（邮箱地址：bairong.shen@scu.edu.cn）。

脚注

作者贡献：HY构思并设计了本研究，开展了研究，进行了模型分析，分析了数据，并撰写了论文；CZ和JL进行了数据分析和临床分析；BS和APS构思并设计了本研究。

利益冲突：未声明。

参考

1. Srzi I、Nesek Adam V、Tunji Pejak D. 脓毒症的定义：治疗指南的新进展。《克罗地亚临床杂志》。2022;61(增刊1):67–72。doi: 10.20471/acc.2022.61.s1.11。 [[DOI](#)] [[PMC免费文章](#)] [[PubMed](#)] [[Google Scholar](#)]
2. Rudd KE, Johnson SC, Agesa KM, Shackelford KA, Tsoi D, Kievlan DR, Colombara DV, Ikuta KS, Kissoon N, Finfer S, Fleischmann-Struzek C, Machado FR, Reinhart KK, Rowan K, Seymour CW, Watson RS, West TE, Marinho F, Hay SI, Lozano R, Lopez AD, Angus DC, Murray CJL, Naghavi M. Global, regional, and national sepsis incidence and mortality, 1990–2017: analysis for the Global burden of disease study. The Lancet. 2020;395(10219):200–211. doi: 10.1016/s0140-6736(19)32989-7. [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]
3. Anggraini D, Hasni D, Amelia R. Pathogenesis of sepsis. Scientific j. 2022;1(4):332–339. doi: 10.56260/sciena.v1i4.63. [[DOI](#)] [[Google Scholar](#)]
4. Baghela A, Pena OM, Lee AH, Baquir B, Falsafi R, An A, Farmer SW, Hurlburt A, Mondragon-Cardona A, Rivera JD, Baker A, Trahtemberg U, Shojaei M, Jimenez-Canizales CE, Santos CCD, Tang B, Bouma HR, Cohen Freue GV, Hancock REW. Predicting sepsis

severity at first clinical presentation: the role of endotypes and mechanistic signatures.

EBioMedicine. 2022;75:103776. doi: 10.1016/j.ebiom.2021.103776.

[https://linkinghub.elsevier.com/retrieve/pii/S2352-3964\(21\)00570-3](https://linkinghub.elsevier.com/retrieve/pii/S2352-3964(21)00570-3) .S2352-3964(21)00570-3 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

5. Liu D, Huang SY, Sun JH, Zhang HC, Cai QL, Gao C, Li L, Cao J, Xu F, Zhou Y, Guan CX, Jin SW, Deng J, Fang XM, Jiang JX, Zeng L. Sepsis-induced immunosuppression: mechanisms, diagnosis and current treatment options. Mil Med Res. 2022;9(1):56. doi: 10.1186/s40779-022-00422-y.

<https://mmrjournal.biomedcentral.com/articles/10.1186/s40779-022-00422-y> .10.1186/s40779-022-00422-y [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

6. Sekino N, Selim M, Shehadeh A. Sepsis-associated brain injury: underlying mechanisms and potential therapeutic strategies for acute and long-term cognitive impairments. J Neuroinflammation. 2022;19(1):101. doi: 10.1186/s12974-022-02464-4.

4. <https://jneuroinflammation.biomedcentral.com/articles/10.1186/s12974-022-02464-4> .10.1186/s12974-022-02464-4 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

7. Chandak P, Huang K, Zitnik M. Building a knowledge graph to enable precision medicine. Sci Data. 2023;10(1):67. doi: 10.1038/s41597-023-01960-3.

<https://doi.org/10.1038/s41597-023-01960-3> .10.1038/s41597-023-01960-3 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

8. Li Z, Zhong Q, Yang J, Duan Y, Wang W, Wu C, He K. DeepKG: an end-to-end deep learning-based workflow for biomedical knowledge graph extraction, optimization and applications. Bioinformatics. 2022;38(5):1477–1479. doi:

10.1093/bioinformatics/btab767. <https://europepmc.org/abstract/MED/34788369>
.6425667 [DOI] [PMC free article] [PubMed] [Google Scholar]

9. OpenAI. Achiam J, Adler S, Agarwal S, Ahmad L, Akkaya I, Aleman FL, Almeida D, Altenschmidt J, Altman S, Anadkat S, Avila R, Babuschkin I, Balaji S, Balcom V, Baltescu P, Bao H, Bavarian M, Belgum J, Bello I, Berdine J, Bernadett-Shapiro GB, Berner C, Bogdonoff L, Boiko O, Boyd M, Brakman AL, Brockman G, Brooks T, Brundage M, et al Gpt-4 technical report. arXiv:2303.08774. 2023 <https://arxiv.org/abs/2303.08774> .
[Google Scholar]

10. Qin M. The uniqueness of LLaMA3-70B with per-channel quantization.
arXiv:2408.15301. 2024 <https://arxiv.org/abs/2408.15301> . [Google Scholar]

11. Hu Y, Chen Q, Du J, Peng X, Keloth VK, Zuo X, Zhou Y, Li Z, Jiang X, Lu Z, Roberts K, Xu H. Improving large language models for clinical named entity recognition via prompt engineering. J Am Med Inform Assoc. 2024 Sep 01;31(9):1812–1820. doi:
10.1093/jamia/ocad259.7590607 [DOI] [PMC free article] [PubMed] [Google Scholar]

12. Yuan C, Xie Q, Ananiadou S. Zero-shot temporal relation extraction with ChatGPT.
arXiv:2304.05454. 2023 <https://arxiv.org/abs/2304.05454> . [Google Scholar]

13. Arvidsson S, Axell J. Prompt engineering guidelines for LLMs in requirements engineering. GUPEA. 2023. [2023-08-07].
<https://gupea.ub.gu.se/handle/2077/77967> .

14. Meskó B. Prompt engineering as an important emerging skill for medical professionals: tutorial. J Med Internet Res. 2023;25:e50638. doi: 10.2196/50638.

<https://www.jmir.org/2023//e50638/> v25i1e50638 [DOI] [PMC free article]
[PubMed] [Google Scholar]

15. Floridi L, Chiriatti M. GPT-3: Its nature, scope, limits, and consequences. *Minds Mach.* 2020;30:681–694. doi: 10.1007/s11023-020-09548-1. [DOI] [Google Scholar]

16. Zhang C, Zhang X, Sun Z, Liu X, Shen B. MetaSepsisBase: a biomarker database for systems biological analysis and personalized diagnosis of heterogeneous human sepsis. *Intensive Care Med.* 2023;49(8):1015–1017. doi: 10.1007/s00134-023-07126-4. 10.1007/s00134-023-07126-4 [DOI] [PubMed] [Google Scholar]

17. Geer LY, Marchler-Bauer A, Geer RC, Han L, He J, He S, Liu C, Shi W, Bryant SH. The NCBI BioSystems database. *Nucleic Acids Res.* 2010;38(Database issue):D492–D496. doi: 10.1093/nar/gkp858. <https://europepmc.org/abstract/MED/19854944> .gkp858 [DOI] [PMC free article] [PubMed] [Google Scholar]

18. Seal RL, Braschi B, Gray K, Jones TEM, Tweedie S, Haim-Vilmovsky L, Bruford EA. Genenames.org: the HGNC resources in 2023. *Nucleic Acids Res.* 2023;51(D1):D1003–D1009. doi: 10.1093/nar/gkac888. <https://europepmc.org/abstract/MED/36243972> .6761747 [DOI] [PMC free article] [PubMed] [Google Scholar]

19. Cock PJA, Antao T, Chang JT, Chapman BA, Cox CJ, Dalke A, Friedberg I, Hamelryck T, Kauff F, Wilczynski B, de Hoon MJL. Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics.* 2009 Jun 01;25(11):1422–3. doi: 10.1093/bioinformatics/btp163. <https://europepmc.org/abstract/MED/19304878> .btp163 [DOI] [PMC free article] [PubMed] [Google Scholar]

20. Ma X. Knowledge graph construction and application in geosciences: A review. *Comput Geosci*. 2022;161:105082. doi: 10.1016/j.cageo.2022.105082. [[DOI](#)] [[Google Scholar](#)]
21. Zamini M, Reza H, Rabiei M. A review of knowledge graph completion. *Information*. 2022;13(8):396. doi: 10.3390/info13080396. [[DOI](#)] [[Google Scholar](#)]
22. Chen Y, Li H, Li H, Liu W, Wu Y, Huang Q, Wan S. An overview of knowledge graph reasoning: key technologies and applications. *J Sens Actuator Netw*. 2022;11(4):78. doi: 10.3390/jsan11040078. [[DOI](#)] [[Google Scholar](#)]
23. Tang X, Feng Z, Xiao Y, Wang M, Ye T, Zhou Y, Meng J, Zhang B, Zhang D. Construction and application of an ontology-based domain-specific knowledge graph for petroleum exploration and development. *Geosci Front*. 2023;14(5):101426. doi: 10.1016/j.gsf.2022.101426. [[DOI](#)] [[Google Scholar](#)]
24. Wang B, Wang Z, Wang X, Cao Y, Saourous RA, Kim Y. Grammar prompting for domain-specific language generation with large language models. *Advances in Neural Information Processing Systems*. 2024:36. <https://arxiv.org/abs/2305.19234>. [[Google Scholar](#)]
25. Gokul A. LLMs and AI: understanding its reach and impact. *Preprints.org*. 2023. [2023-05-04]. <https://www.preprints.org/manuscript/202305.0195/v1>.
26. Kirk JR, Wray RE, Lindes P, Laird JE. Improving knowledge extraction from LLMs for task learning through agent analysis. *Proceedings of the AAAI Conference on Artificial Intelligence*. 2024;38(16):18390–18398. doi: 10.1609/aaai.v38i16.29799. [[DOI](#)] [[Google Scholar](#)]

27. Kojima T, Shane Gu, SS, Reid, M, Matsuo Y, Iwasawa Y. Large language models are zero-shot reasoners. arXiv:2205.11916. 2022;35 <https://arxiv.org/abs/2205.11916> .

[[Google Scholar](#)]

28. Kang S, Yoon J, Yoo S. Large language models are few-shot testers: exploring LLM-based general bug reproduction. IEEE/ACM 45th International Conference on Software Engineering (ICSE); May 14-20, 2023; Melbourne, Australia. 2023. [[DOI](#)] [[Google Scholar](#)]

29. Zhang N, Chen M, Bi Z, Liang X, Li L, Shang X, Yin K, Tan C, Xu J, Huang F, Si L, Ni Y, Xie G, Sui Z, Chang B, Zong H, Yuan Z, Li L, Yan J, Zan H, Zhang K, Tang B, Chen Q. CBLUE: a Chinese Biomedical Language Understanding Evaluation benchmark. ArXiv. Preprint posted online on June 15, 2021. <https://arxiv.org/abs/2106.08087> . [[Google Scholar](#)]

30. Rasmy L, Xiang Y, Xie Z, Tao C, Zhi D. Med-BERT: pretrained contextualized embeddings on large-scale structured electronic health records for disease prediction. NPJ Digit Med. 2021;4(1):86. doi: 10.1038/s41746-021-00455-y.

<https://doi.org/10.1038/s41746-021-00455-y> .10.1038/s41746-021-00455-y

[[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

31. Graves A. Supervised Sequence Labelling with Recurrent Neural Networks. Berlin, Heidelberg: Springer; 2012. Long short-term memory; pp. 37–45. [[Google Scholar](#)]

32. Neumann M, Daniel King D, Beltagy I, Ammar W. ScispaCy: fast and robust models for biomedical natural language processing. arXiv:1902.07669. 2019 doi:

10.18653/v1/w19-5034. [[DOI](#)] [[Google Scholar](#)]

33. Bodenreider O. The unified medical language system (UMLS): integrating biomedical terminology. *Nucleic Acids Res.* 2004;32(Database issue):D267–D270. doi: 10.1093/nar/gkh061.32/suppl_1/D267 [DOI] [PMC free article] [PubMed] [Google Scholar]
34. Souza F, Nogueira R, Lotufo R. Portuguese named entity recognition using BERT-CRF. arXiv:1909.10649. 2019 <https://arxiv.org/abs/1909.10649> . [Google Scholar]
35. Zhang Y, Liao X, Chen L, Kang H, Cai Y, Wang Q. Health Information Science. Cham: Springer; 2021. Multi-BERT-wwm model based on probabilistic graph strategy for relation extraction. [Google Scholar]
36. Zhang Y, Yang J. Chinese NER using lattice LSTM. arXiv:1805.02023. 2018 doi: 10.18653/v1/p18-1144. <https://arxiv.org/abs/1805.02023> . [DOI] [Google Scholar]
37. Multicenter Sepsis Database (MSD): based on real-world clinical data. Multicentric Sepsis Database. [2025-03-06]. <http://sysbio.org.cn/MSD> .
38. Edge D, Trinh H, Cheng N, Bradley J, Chao A, Mody A, Truitt S, Metropolitansky D, Ness RO, Larson J. From local to global: a graph RAG approach to query-focused summarization. arXiv:2404.16130. 2024 <https://arxiv.org/abs/2404.16130> . [Google Scholar]
39. Post M. A call for clarity in reporting BLEU scores. arXiv:1804.08771. 2018 doi: 10.18653/v1/w18-6319. <https://arxiv.org/abs/1804.08771> . [DOI] [Google Scholar]

40. Lin CY. Rouge: a package for automatic evaluation of summaries. Proceedings of the Workshop on Text Summarization Branches Out (WAS 2004); July 25, 2004; Barcelona, Spain. 2004. <https://www.semanticscholar.org/paper/ROUGE%3A-A-Package-for-Automatic-Evaluation-of-Lin/60b05f32c32519a809f21642ef1eb3eaf3848008> .
[[Google Scholar](#)]
41. Cha JK, Kim HS, Kim EJ, Lee ES, Lee JH, Song IA. Effect of early nutritional support on clinical outcomes of critically ill patients with sepsis and septic shock: a single-center retrospective study. *Nutrients*. 2022;14(11):2318. doi: 10.3390/nu14112318.
<https://www.mdpi.com/resolver?pii=nu14112318> .nu14112318 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]
42. Jiang L, Cheng M. Impact of diabetes mellitus on outcomes of patients with sepsis: an updated systematic review and meta-analysis. *Diabetol Metab Syndr*. 2022;14(1):39. doi: 10.1186/s13098-022-00803-2.
<https://dmsjournal.biomedcentral.com/articles/10.1186/s13098-022-00803-2> .10.1186/s13098-022-00803-2 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]
43. Wang Z, Zhang L, Xu F, Han D, Lyu J. The association between continuous renal replacement therapy as treatment for sepsis-associated acute kidney injury and trend of lactate trajectory as risk factor of 28-day mortality in intensive care units. *BMC Emerg Med*. 2022;22(1):32. doi: 10.1186/s12873-022-00589-6.
<https://bmccemergmed.biomedcentral.com/articles/10.1186/s12873-022-00589-6> .10.1186/s12873-022-00589-6 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]
44. Meng Z, Pan L, Qian S, Yang X, Pan L, Chi R, Chen J, Pan J, Shi C. Antimicrobial peptide nanoparticles coated with macrophage cell membrane for targeted antimicrobial

therapy of sepsis. Mater Des. 2023;229:111883. doi: 10.1016/j.matdes.2023.111883.

[[DOI](#)] [[Google Scholar](#)]

45. Lukaszewski RA, Jones HE, Gersuk VH, Russell P, Simpson A, Brealey D, Walker J, Thomas M, Whitehouse T, Ostermann M, Koch A, Zacharowski K, Kruhoffer M, Chaussabel D, Singer M. Presymptomatic diagnosis of postoperative infection and sepsis using gene expression signatures. Intensive Care Med. 2022;48(9):1133–1143. doi: 10.1007/s00134-022-06769-z. <https://europepmc.org/abstract/MED/35831640>. 10.1007/s00134-022-06769-z [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

46. Carpenter KC, Hakenjos JM, Fry CD, Nemzek JA. The influence of pain and analgesia in rodent models of sepsis. Comp Med. 2019;69(6):546–554. doi: 10.30802/aalas-cm-19-000004. [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

47. Mayow AH, Ahmad F, Afzal MS, Khokhar MU, Rafique D, Vallamchetla SK, Palleti SK, Saleem F. A systematic review and meta-analysis of independent predictors for acute respiratory distress syndrome in patients presenting with sepsis. Cureus. 2023;15(4):e37055. doi: 10.7759/cureus.37055. <https://europepmc.org/abstract/MED/37143620> . [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

48. Tyszko M, Lemańska-Perek A, Śmiechowicz J, Tomaszewska P, Biecek P, Goździk W, Adamik B. Citrulline, intestinal fatty acid-binding protein and the acute gastrointestinal injury score as predictors of gastrointestinal failure in patients with sepsis and septic shock. Nutrients. 2023;15(9):2100. doi: 10.3390/nu15092100. <https://www.mdpi.com/resolver?pii=nu15092100> .nu15092100 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

49. Bronicki RA, Tume SC, Flores S, Loomba RS, Borges NM, Penny DJ, Burkhoff D. The cardiovascular system in severe sepsis: insight from a cardiovascular simulator. *Pediatr Crit Care Med*. 2022;23(6):464–472. doi: 10.1097/PCC.0000000000002945.00130478-202206000-00008 [[DOI](#)] [[PubMed](#)] [[Google Scholar](#)]

50. Bazaid AS, Aldarhami A, Gattan H, Barnawi H, Qanash H, Alsaif G, Alharbi B, Alrashidi A, Eldrehmy EH. Antibigram of urinary tract infections and sepsis among infants in neonatal intensive care unit. *Children (Basel)* 2022;9(5):629. doi: 10.3390/children9050629. <https://www.mdpi.com/resolver?pii=children9050629>.children9050629 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

51. Becker AE, Teixeira SR, Lunig NA, Mondal A, Fitzgerald JC, Topjian AA, Weiss SL, Griffis H, Schramm SE, Traynor DM, Vossough A, Kirschen MP. Sepsis-related brain MRI abnormalities are associated with mortality and poor neurological outcome in pediatric sepsis. *Pediatr Neurol*. 2022;128:1–8. doi: 10.1016/j.pediatrneurol.2021.12.001. <https://europepmc.org/abstract/MED/34992035>.S0887-8994(21)00259-9 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

52. Wang C, Liu S, Yang H, Guo J, Wu Y, Liu J. Ethical considerations of using ChatGPT in health care. *J Med Internet Res*. 2023;25:e48009. doi: 10.2196/48009. <https://www.jmir.org/2023//e48009/> v25i1e48009 [[DOI](#)] [[PMC free article](#)] [[PubMed](#)] [[Google Scholar](#)]

53. Aydin I, Diebel-Fischer H, Freiburger V, Möller-Klapperich J, Buchmann E, Färber M, Lauber-Rönsberg A, Platow B. Assessing privacy policies with AI: ethical, legal, and technical challenges. *arXiv:2410.08381v1*. 2024 <https://arxiv.org/html/2410.08381v1> . [[Google Scholar](#)]

54. Google GT, Anil R, Borgeaud S, Alayrac JB, Yu J, Soricut R, Schalkwyk J, Dai AM, Hawth A, Millican K, Silver D, Johnson M, Antonoglou I, Schrittwieser J, Glaese A, Chen J, Pitler E, Lillicrap T, Lazaridou A, Firat O, Molloy J, Isard M, Barham PR, Hennigan T, Lee B, Viola F、Reynolds M、Xu Y、Doherty R、Collins E 等 Gemini：一系列高性能多模式模型。arXiv: 2312.11805。2023 <https://arxiv.org/abs/2312.11805> 。[[谷歌学术](#)]

55. Wu S, Koo M, Blum L, Black A, Kao L, Scalzo F, Kurtz I. 开源大型语言模型 GPT-4 和 Claude 2 在肾脏病学多项选择题测试中的比较研究。arXiv:2308.04709。2023 <https://arxiv.org/abs/2308.04709> 。[[谷歌学术](#)]

56. 胡恩杰、沈宇、Wallis P、Allen-Zhu Z、李勇、王硕、王磊、陈伟. LoRA：大型语言模型的低秩自适应. arXiv:2106.09685. 2021 <https://arxiv.org/abs/2106.09685> 。[[Google Scholar](#)]

57. Tam WL、Liu X、Ji K、Xue L、Zhang X、Dong Y、Liu J、Hu M、Tang J. 参数高效的提示调优实现了通用且校准的神经文本检索器。arXiv:2207.07087。2022。doi: 10.18653/v1/2023.findings-emnlp.874。https ://arxiv.org/abs/2207.07087 。 [[DOI](#)] [[Google Scholar](#)]

58. Zhou S, Yu S. 基于大型语言模型的半结构化网络文章高通量生物学关系抽取. arXiv:2312.08274. 2023 <https://arxiv.org/abs/2312.08274> 。[[Google Scholar](#)]

59. Karmaker Santu SK, Feng D. TELeR：用于复杂任务基准测试的LLM提示通用分类法。arXiv:2305.11430。2023 doi: 10.18653/v1/2023.findings-emnlp.946。https ://arxiv.org/abs/2305.11430 。 [[DOI](#)] [[Google Scholar](#)]

相关数据

本节收集本文中包含的任何数据引用、数据可用性声明或补充材料。

补充材料

多媒体附录 1

附加信息。

[jmir v27i1e65537_app1.docx](#) (1.5MB, docx)

数据可用性声明

为确保数据安全，数据库目前不支持直接在网站上下载。如有需要，研究人员可通过电子邮件联系华西医院疾病系统遗传学研究所所长沈百荣教授（邮箱地址：bairong.shen@scu.edu.cn）。

本文由JMIR Publications Inc.提供，特此致谢。